UNIVERSITÉ CÔTE D'AZUR

UNIVERSITÉ CÔTE D'AZUR | ÉCOLE DOCTORALE DROIT ET SCIENCES POLITIQUES, ÉCONOMIQUES ET DE GESTION

Master Expertise et Analyse des Données Économiques (EADE)

Mémoire de Master 2

Rapport de stage

Présenté par : Thibault PHILIBERT

Poste : *Data Analyst*

Structure d'accueil : *École Doctorale DESPEG (ED 513) - Université Côte d'Azur*

Tuteur académique :

Mme Anna TYKHONENKO

Professeur des Universités

Tuteurs en entreprise :

Mme Flora BELLONE

Directrice de l'Ecole Doctoral

M. Philippe LUPPI

Directeur adjoint de l'Ecole Doctoral

Année universitaire 2025-2026

Remerciements

Je tiens en premier lieu à remercier chaleureusement Madame Flora Bellone, Directrice de l'École Doctorale DESPEG, ainsi que Monsieur Philippe Luppi, Directeur adjoint, pour m'avoir accordé leur confiance. Leur accueil et la grande autonomie qu'ils m'ont laissée dans la conception de ce projet ont été des facteurs déterminants dans la réussite de cette mission.

Mes remerciements s'adressent également à Madame Anna Tykhonenko, ma tutrice académique, pour son suivi, ses conseils avisés et son accompagnement. Savoir que je pouvais compter sur elle en « back-up » a été particulièrement rassurant ; sa présence et ses recommandations ont toujours su dissiper mes inquiétudes lors des moments de doute.

Je souhaite adresser une pensée toute particulière à Madame Iwona Pieczyrak et Madame Rokhaya Diop, gestionnaires administratives de l'École Doctorale, avec qui j'ai eu la chance de partager le bureau. Je les remercie pour leur infinie patience, leur bonne humeur communicative et leur sympathie au quotidien. Elles ont toujours pris le temps de répondre à mes nombreuses questions pour m'aider à décrypter les logiques institutionnelles (financements, cotutelles, etc.) indispensables à la création de mon outil.

Je remercie sincèrement Monsieur Michele Pezzoni, Maître de conférences, pour son aide précieuse et son regard expert sur la partie économétrique de ce mémoire. Mes remerciements vont également à Monsieur Jean de Peña, consultant externe, pour la qualité de sa formation et sa disponibilité pour répondre à toutes mes interrogations techniques, notamment sur l'environnement WordPress.

Plus largement, je tiens à remercier l'ensemble du corps professoral du Master EADE pour la grande qualité des enseignements dispensés et les précieux conseils prodigués tout au long de l'année.

Enfin, une dédicace toute spéciale à ma promotion. J'ai été particulièrement fier d'en être le délégué. Merci pour ces liens forts que nous avons tissés, et pour avoir partagé avec moi les difficultés de travail, les sessions de sport et les nombreux fous rires qui ont ponctué cette année.Ainsi qu'à mes proches pour leur soutien indéfectible tout au long de mon cursus universitaire.

Table des matières

Remerciements **1**
Introduction Générale **4**

Partie I : Data Engineering et Business Intelligence 5

A) Présentation de l'École Doctorale DESPEG et de son environnement **5**
1) Un pôle pluridisciplinaire au cœur de l'Université Côte d'Azur 5
2) Le besoin métier : Piloter la donnée dans un environnement fragmenté 5
3) Mon positionnement et le cadre de travail 6

B) Outils mobilisés **6**
1) Environnement de développement et architecture Python 7
2) Modélisation analytique : Microsoft Power BI et DAX 7
3) Automatisation de la collecte : LimeSurvey 7
4) Valorisation digitale : WordPress 7

C) Missions réalisées et compétences mobilisées **8**
1) Logique de fonctionnement de l'outil 8
2) Détail technique du pipeline 9
3) Modélisation et restitution analytique (Business Intelligence) 10
4) Passation, documentation et livrables finaux 12

Conclusion de la Partie I **13**

Partie II : Étude économétrique des déterminants de l'achèvement de la thèse 15

A) Introduction **15**

B) Revue de littérature **15**
1) Un marché du travail académique sous tension 16
2) L'impact de l'écosystème local : Encadrement et dynamique de groupe 16
3) Le paradoxe du financement et l'adaptation des trajectoires 16

C) Création de la base de données **17**
1) Centralisation des fichiers ADUM et anonymisation 17
2) Ingénierie des variables et catégorisation des profils 17
3) Identification des trajectoires de sortie 18

D) Echantillonnage et statistiques descriptives **18**
1) Stratégie d'échantillonnage et transformation des données 19
2) Statistiques descriptives de l'échantillon 19

E) Méthodologie et Résultats **21**
1) Méthodologie Économétrique 22
2) Résultats 23

F) Conclusion **25**

Conclusion Générale **26**

Bibliographie **27**

Annexes **28**
Annexe 1 : Architecture globale et Diagramme de processus ETL 28
Annexe 2 : Arbre de décision de la taxonomie des financements 29
Annexe 3 : Modélisation et traitement des départs 29
Annexe 4 : Typologie de l'insertion professionnelle post-thèse 30
Annexe 5 :Vues complémentaires des tableaux de bord Power BI 31

Table des figures

Figure 1 : Vue d'ensemble du tableau de bord "Statistiques Institutionnelles" . . . 11
Figure 2 : Analyse de la dynamique d'insertion à T+1, T+3 et T+5 12
Figure 3 : Distribution de l'âge à l'inscription en doctorat 20
Figure 4 : Logigramme de l'architecture ETL développée sous Python 28
Figure 5 : Classification des types de financements de la thèse 29
Figure 6 : Arbre décisionnel de traitement des trajectoires d'abandon 29
Figure 7 : Classification hiérarchique de l'insertion professionnelle 30
Figure 8 : Attractivité et financement des nouveaux entrants 31
Figure 9 : Soutenances et abandons 31
Figure 10 : Parité 32
Figure 11 : Historique 32
Figure 12 : Vue d'ensemble de la situations professionnelles 33

Liste des tableaux

Tableau 1 : Statistiques descriptives de l'échantillon d'analyse 20
Tableau 2 : Matrice de corrélation 21
Tableau 3 : Déterminants de la soutenance en trois ans 23
Tableau 4 : Déterminants de la soutenance en trois ans avec variable d'interaction 34

Introduction Générale

L'École Doctorale "Droit et Sciences Politiques, Économiques et de Gestion" (ED DESPEG) de l'Université Côte d'Azur assure le suivi quotidien de près de deux cents doctorants. Pour mener à bien cette mission, l'administration s'appuie principalement sur le système national ADUM. Cependant, cette base de données repose sur des saisies purement déclaratives, générant inévitablement des incohérences, des valeurs manquantes et un format brut difficilement exploitable. Face au manque de temps et d'outils analytiques adaptés, l'équipe de direction peinait à extraire des statistiques fiables et à suivre efficacement l'insertion professionnelle de ses jeunes docteurs, freinant ainsi le pilotage stratégique de l'institution.

C'est pour répondre à ce besoin critique de structuration de l'information que j'ai intégré l'ED DESPEG en tant que *Data Analyst*. Cette mission s'inscrivait en parfaite adéquation avec les exigences de mon cursus au sein du Master Expertise et Analyse des Données Économiques (EADE). Plongé au cœur d'une véritable problématique métier, j'ai eu l'opportunité d'évoluer avec une grande autonomie. La conception d'une solution algorithmique de bout en bout et la satisfaction d'apporter un outil ayant un impact immédiat et concret sur l'organisation ont rendu cette expérience particulièrement stimulante.

Pour restituer la globalité de ce travail, ce mémoire s'articule autour de deux grands axes complémentaires.

La **Première Partie** retrace ma mission principale en entreprise, consacrée au *Data Engineering* et à la *Business Intelligence*. L'objectif a été de développer un pipeline ETL *(Extract, Transfor, Load)* robuste sous Python pour nettoyer et auditer les registres d'ADUM. Ce travail a abouti au déploiement d'un progiciel automatisant les campagnes statistiques et les enquêtes d'insertion (Alumni). La donnée purifiée a ensuite été modélisée sous Microsoft Power BI, dotant la direction d'un outil d'aide à la décision interactif et pérenne.

La **Seconde Partie** exploite l'infrastructure technique construite lors de mon stage pour répondre à une problématique de recherche académique. Bien que l'analyse économétrique ne fît pas partie de mes attributions initiales au sein de l'École Doctorale, la qualité et la fiabilité du panel anonymisé généré par mon pipeline m'ont permis de l'utiliser pour étudier les déterminants de l'achèvement de la thèse. Nous y analyserons les facteurs individuels, académiques et matériels qui favorisent une soutenance dans le délai réglementaire de trois ans, mettant en lumière des disparités structurelles fortes et le rôle paradoxal du contrat doctoral.

Partie I : Data Engineering et Business Intelligence au service de l'École Doctorale

A) Présentation de l'École Doctorale DESPEG et de son environnement

1) Un pôle pluridisciplinaire au cœur de l'Université Côte d'Azur

L'École Doctorale "Droit et Sciences Politiques, Économiques et de Gestion" (ED DESPEG - ED 513) est une structure de l'Université Côte d'Azur (UniCA). Son rôle est de préparer au doctorat dans quatre champs disciplinaires majeurs, favorisant les synergies méthodologiques entre juristes, politistes, économistes et gestionnaires.

En 2025-2026, l'ED DESPEG comptait 198 doctorants répartis sur six sections du Conseil National des Universités (CNU), encadrés par 171 directeurs de recherche habilités. Ces doctorants évoluent au sein de 7 laboratoires de recherche accrédités :

- **CERDACFF :** Centre d'Études et de Recherche en Droit Administratif, Constitutionnel, Financier et Fiscal.
- **CERDP :** Centre d'Études et de Recherche en Droit des Procédures.
- **ERMES :** Équipe de Recherche sur les Mutations de l'Europe et de ses Sociétés.
- **GREDEG :** Groupe de Recherche en Droit, Économie et Gestion.
- **GRM :** Groupe de Recherche en Management.
- **LADIE :** Laboratoire de Droit International et Européen.
- **SRC :** SKEMA Research Center.

La structure est dirigée par Madame Flora Bellone (Directrice) et Monsieur Philippe Luppi (Directeur adjoint), appuyés par deux gestionnaires administratives (Iwona Pieczyrak et Rokhaya Diop).

2) Le besoin métier : Piloter la donnée dans un environnement fragmenté

La mission principale de l'ED DESPEG est d'accompagner le parcours des doctorants (inscriptions, financements, événements institutionnels comme les Doctoriales). Pour ce faire, l'administration s'appuie principalement sur l'application nationale ADUM, qui centralise les informations liées à la formation doctorale. Toutefois, cette base de données repose sur un système purement déclaratif, ce qui génère des biais de saisie, des incohérences et complexifie l'exploitation brute des informations.

Comme identifié par la direction, le pilotage stratégique de l'école se heurtait non seulement à une fragmentation de la donnée, mais également à son inaccessibilité. De nombreuses statistiques institutionnelles clés pour l'ED DESPEG étaient complexes à obtenir, voire totalement inexistantes. Ce manque de visibilité était particulièrement critique concernant l'insertion professionnelle des diplômés. En effet, bien que le suivi du devenir de ses anciens doctorants fasse partie intégrante de ses missions institutionnelles, l'école ne disposait que de très peu d'informations et n'avait quasiment aucune vision globale sur ce domaine. Les rares données exploitables étaient dispersées entre les réseaux sociaux professionnels (notamment LinkedIn) et les enquêtes annuelles d'UniCA. L'ED DESPEG souffrait ainsi d'un manque d'outils analytiques unifiés pour évaluer son attractivité, suivre les parcours de ses doctorants et mesurer sa performance institutionnelle de manière pérenne.

3) Mon positionnement et le cadre de travail

C'est pour répondre à ce besoin critique de pilotage par la donnée que j'ai intégré l'ED DESPEG en tant que *Data Analyst*. Ma mission principale, définie par Madame Bellone, consistait à concevoir une architecture logicielle capable d'extraire, de nettoyer et de croiser ces différentes sources (ADUM, LinkedIn, enquêtes) afin de produire un tableau de bord dynamique et automatisable.

L'une des spécificités formatrices de ce stage a été sa complexité organisationnelle. J'ai évolué en totale autonomie technique, sans la supervision d'un *Lead Data* senior, ce qui m'a imposé de valider moi-même mes choix d'architecture, du recueil des besoins auprès de la direction jusqu'à la mise en production technique.

Par ailleurs, le rythme de travail a exigé une forte capacité d'adaptation. Débutée sous un format d'alternance me permettant de concilier cette mission avec mon Master 2 EADE, la période de stage a été marquée par un passage en télétravail complet et un changement de tuteur en cours de projet. Ces contraintes ont renforcé ma rigueur dans la documentation de mon code et dans la communication des livrables (comptes rendus hebdomadaires, documentation technique) pour garantir la continuité du projet. Enfin, en parallèle de mon cœur de métier d'ingénierie des données, j'ai ponctuellement assisté l'administration dans des tâches transverses, telles que la production de tableaux Excel, l'assistance logistique lors des Doctoriales, le déploiement des outils de visioconférence (Zoom), et l'aide à la mise en page documentaire.

B) Outils mobilisés

Mon stage a nécessité le déploiement d'un ensemble d'outils divers, allant de l'extraction des données brutes à leur restitution visuelle et institutionnelle.

1) Environnement de développement et architecture Python

Le cœur du pipeline ETL *(Extract, Transfor, Load)* a été intégralement codé en Python sous l'environnement Visual Studio Code. Le script mobilise plusieurs bibliothèques pour traiter la complexité des registres de l'ED DESPEG :

— **Traitement de la donnée :** `pandas` constitue le moteur de manipulation des bases (lecture, modification, jointures et export Excel), appuyé par `numpy` pour le traitement des conditions logiques complexes. L'harmonisation textuelle, indispensable face aux saisies déclaratives d'ADUM, a été sécurisée par `unicodedata` (gestion stricte des accents).

— **Interface graphique (GUI) :** Afin de livrer un outil pérenne et utilisable par l'administration (non-développeurs), une interface visuelle a été conçue grâce à `customtkinter` et `tkinter`.

— **Système et sécurité :** L'automatisation des flux de fichiers, la sécurisation des chemins relatifs et l'horodatage des sauvegardes ont été gérés via `os`, `sys`, `shutil` et `datetime`.

— **Déploiement institutionnel :** Pour contourner les blocages liés aux antivirus de l'Université Côte d'Azur et faciliter l'installation par le personnel administratif, l'ensemble du projet a été packagé et configuré sous la forme d'un environnement Python portable.

2) Modélisation analytique : Microsoft Power BI et DAX

La restitution des données nettoyées a été réalisée sur Power BI sous la forme de tableaux de bord complets et interactifs. Il ne s'agissait pas d'une simple exploration de la base, mais d'un véritable projet de *Data Visualisation* destiné au pilotage stratégique de la direction. La conception de ces indicateurs de performance a nécessité l'écriture de requêtes en langage DAX (*Data Analysis Expressions*), ce qui a permis de générer des mesures dynamiques, d'intégrer des filtres de navigation, et de consolider le modèle relationnel entre les différentes tables d'informations.

3) Automatisation de la collecte : LimeSurvey

Pour combler les lacunes concernant l'insertion professionnelle, l'outil LimeSurvey a été intégré au processus. Le travail a consisté à développer des "canevas" de questionnaires standardisés. L'administration n'a désormais plus qu'à dupliquer ces trames, ajuster les intitulés et y injecter la base de contacts proprement générée par le script Python pour lancer des campagnes d'enquêtes massives.

4) Valorisation digitale : WordPress

Le volet communication institutionnelle a été opéré sur le CMS *Content Management System* WordPress du site de l'École Doctorale. Disposant de droits d'édition (le niveau de permission précédant l'administration complète) et suite à une formation dédiée, j'ai pu intervenir

directement sur le contenu web pour concevoir et restructurer des pages spécifiques (telles que la section dédiée à la mobilité internationale entrante ou la page insertion professionnelle).

C) Missions réalisées et compétences mobilisées

1) Logique de fonctionnement de l'outil

Le cœur de mon stage n'était pas de concevoir un simple script informatique, mais de déployer un outil pérenne répondant aux deux missions qui m'avaient été confiées par l'ED DESPEG : le pilotage des statistiques institutionnelles et le suivi de l'insertion professionnelle des docteurs.

Pour répondre à ce besoin, j'ai fait le choix de développer un pipeline ETL reposant sur la collaboration "Homme-Machine". L'algorithme se charge des tâches fastidieuses (croisement des bases, nettoyage textuel, calculs), mais laisse le contrôle final et l'arbitrage aux gestionnaires de l'École Doctorale. Lors du traitement, les données manquantes ou incohérentes sont estampillées « A vérifier » dans des fichiers Excel générés sur mesure. L'équipe administrative n'a plus qu'à utiliser des menus déroulants préconfigurés pour corriger les anomalies, remettant ainsi l'expertise humaine au centre de la validation.

Ce processus a été modélisé pour suivre le calendrier annuel de l'ED DESPEG, scindé en deux grandes campagnes :

— **La campagne Statistiques (Mars/Avril) :** Le processus s'effectue en deux temps. Le script génère d'abord des fichiers brouillon. Une fois les données corrigées par les gestionnaires (s'il y a des données à corriger), un second mode "Validation" est lancé. Ce dernier vérifie que toutes les anomalies ont été levées, fige les données dans un dossier d'archivage sécurisé ("Mémoire"), et calcule les indicateurs de performance (KPIs) pour alimenter l'historique de l'école.

— **La campagne Insertion Professionnelle (Juin) :** Cette campagne vise à enquêter sur les cohortes d'anciens doctorants à des horizons précis : 1 an (T+1), 3 ans (T+3) et 5 ans (T+5) après leur soutenance. Le processus est plus itératif. Le script génère d'abord les bases de suivi et une liste de contacts formatée pour l'outil de sondage LimeSurvey. Après l'envoi des questionnaires et une phase de recherche manuelle sur LinkedIn par l'équipe, le script est relancé pour cibler les profils toujours introuvables. Il génère alors un fichier listant automatiquement les anciens directeurs de thèse à contacter pour obtenir des informations. Une fois la base totalement renseignée, l'étape finale fige les données et vient enrichir un fichier central regroupant l'historique complet des carrières.

Déploiement et prise en main par les utilisateurs : Les utilisateurs finaux de cette solution étant des membres de l'équipe administrative non-initiés à la programmation, une attention particulière a été portée à l'expérience utilisateur et aux contraintes de déploiement. Face aux

restrictions strictes de sécurité informatique de l'Université (les antivirus institutionnels pouvant bloquer systématiquement les fichiers compilés classiques de type .exe), j'ai opté pour la configuration d'un environnement Python "portable". Cette approche technique permet de faire "tourner" l'algorithme de manière totalement autonome sur n'importe quel poste, sans nécessiter de droits d'administrateur pour l'installation et sans déclencher l'anti-virus. De plus, pour ne pas dérouter les utilisateurs avec un affichage de code brut, le lancement du pipeline s'effectue via un simple script d'exécution (.bat). Ce dernier est paramétré pour lancer la console en arrière-plan de manière invisible. L'équipe administrative interagit ainsi uniquement avec une interface graphique épurée et rassurante, masquant toute la complexité technologique sous-jacente.

2) Détail technique du pipeline

Lors de la conception de ce pipeline ETL sous Python, ma priorité a été l'anticipation des risques. Sachant que la manipulation de bases de données déclaratives est sujette aux erreurs de saisie humaine, aux valeurs manquantes et aux modifications imprévues d'ADUM, j'ai pensé cette architecture non pas comme un simple script, mais comme un progiciel robuste aux erreurs, capable de les identifier et de les isoler avec précision (le logigramme complet modélisant cette architecture et ses différents flux est consultable en Annexe 1).

Avant même de sécuriser le traitement, il a fallu structurer l'information. En collaboration avec ma tutrice, nous avons défini une nomenclature métier rigoureuse pour classifier les trajectoires (catégorisation des types de financements, statuts d'insertion professionnelle, motifs d'abandon). L'algorithme a été programmé pour appliquer automatiquement cette taxonomie complexe (les arbres de décision détaillant ces classifications sont disponibles en annexes 2, 3 et 4).

L'objectif était de cartographier chaque point de défaillance potentiel (erreur utilisateur, corruption de fichier, changement de format) pour le neutraliser en amont ou pour prévenir l'utilisateur d'une erreur. Pour garantir une tolérance zéro face aux anomalies, j'ai ajouté un ensemble de contrôles de sécurité préventifs agissant à quatre niveaux :

— **Filtres d'intégrité (Le contrôle qualité en entrée) :** Avant toute manipulation, le script agit comme un "douanier" bloquant. Il vérifie la présence physique des fichiers, valide l'existence des colonnes requises grâce à un dictionnaire dynamique (pour pallier les changements de nommage d'ADUM d'une année sur l'autre), et scrute l'intégrité des variables critiques (règle de l'Anti-NA).

— **Harmonisation textuelle et jointures sécurisées :** La nature déclarative d'ADUM générant une forte hétérogénéité, une fonction de lissage s'appuyant sur la norme Unicode (NFKD) neutralise systématiquement les accents et uniformise les données. En parallèle, les clés de jointure (Matricules) sont nettoyées via des expressions régulières (Regex) pour garantir des fusions de tables parfaites. Si une anomalie survient lors d'une fusion

(ex : un étudiant dupliqué par erreur dans l'extraction ADUM), un algorithme intercepte l'erreur critique (`MergeError`) et isole le matricule du doublon.

— **Génération de matrices de saisie intelligentes (Bridage utilisateur) :** Pour limiter les erreurs lors des interventions administratives, le script génère des fichiers brouillon Excel partiellement verrouillé. Le code Python écrit dynamiquement des onglets cachés et des menus déroulants en cascade (*Data Validation*). Une mise en forme conditionnelle est également intégrée : les données manquantes s'affichent en jaune (« A vérifier »), tandis que les incohérences logiques (ex : contradiction entre le contrat réel et les déclarations financières SIREDO) déclenchent une alerte rouge.

— **Boucliers Système et Airbag d'Urgence :** Pour protéger l'environnement de travail, un "Vigile" teste les accès en écriture et bloque le processus si un fichier cible est déjà ouvert par un utilisateur, prévenant ainsi toute corruption. Des boucliers anti-écrasement scannent l'arborescence pour empêcher l'altération des archives validées ("Mémoire"). Enfin, en cas d'erreur inattendue échappant aux autres sécurités, une fonction globale ("Airbag") intercepte le crash avant la fermeture brutale de l'application.

Lorsqu'une anomalie est détectée par l'un de ces quatre niveaux de contrôle, le processus est interrompu de manière totalement sécurisée. L'utilisateur est alors immédiatement alerté via une interface graphique (fenêtre *pop-up*) qui explique l'erreur et identifie précisément les matricules posant problème. En parallèle, le script génère automatiquement un registre détaillé (fichiers de logs au format Excel ou TXT) dans un dossier dédié, fournissant à l'équipe administrative un bilan d'audit clair pour corriger les données à la source dans ADUM. Pour certains problèmes comme fermer un fichier, il est possible de corriger l'erreur et de relancer le code directement depuis la fenêtre *pop-up*.

3) Modélisation et restitution analytique (Business Intelligence)

L'aboutissement du pipeline de données réside dans son utilité pour l'ED DESPEG. Pour transformer les bases générées en un véritable outil d'aide à la décision pour la direction de l'ED DESPEG, la phase de *Data Visualisation* sur Microsoft Power BI s'est articulée autour de la conception de deux tableaux de bord institutionnels. L'élaboration de ces supports a fait l'objet de nombreuses réunions itératives avec la direction afin de définir précisément chaque indicateur et d'aboutir à des visuels offrant un véritable appui au pilotage.

Pour garantir la pérennité de l'outil, la connexion entre le pipeline Python et Power BI a été pensée de manière statique et paramétrable. Plutôt que de générer des fichiers horodatés, le script Python met à jour des bases de données aux noms invariables (ex : `DB_Final_1.xlsx` pour les statistiques, et `DB_Alumni_PBI.xlsx` pour l'insertion). Ainsi, l'intégration d'une nouvelle campagne annuelle se fait en un simple clic sur le bouton "Actualiser" de Power BI, sans jamais avoir à reconfigurer les sources de données. De plus, Power BI ne gérant pas nativement les chemins de fichiers relatifs, j'ai anticipé la migration du livrable sur les postes de l'équipe

administrative. J'ai configuré un paramètre global dans Power Query contenant le chemin d'accès absolu du dossier racine. Toutes les requêtes d'importation sont construites dynamiquement à partir de cette variable. Lors d'un changement d'ordinateur, il suffit de modifier ce chemin unique une seule fois pour reconnecter instantanément l'intégralité du modèle de données.

Le projet s'articule autour de deux rapports Power BI distincts, bénéficiant tous deux de titres "responsifs" (changeant en fonction des filtres et des années) et de segments de filtrage globaux (Discipline, Laboratoire).

1. Le Tableau de Bord "Statistiques Institutionnelles" : Ce rapport très exhaustif se décline en plusieurs vues analytiques permettant d'explorer l'année universitaire en cours sous différents prismes :

— **Vue d'ensemble et Attractivité :** Suivi des effectifs totaux, du taux de financement des nouveaux entrants et de l'attractivité extérieure via l'origine du diplôme de Master (Voir Figure 8 dans l'annexes 5). La vue d'ensemble est à voir Figure 1 ci-dessous.

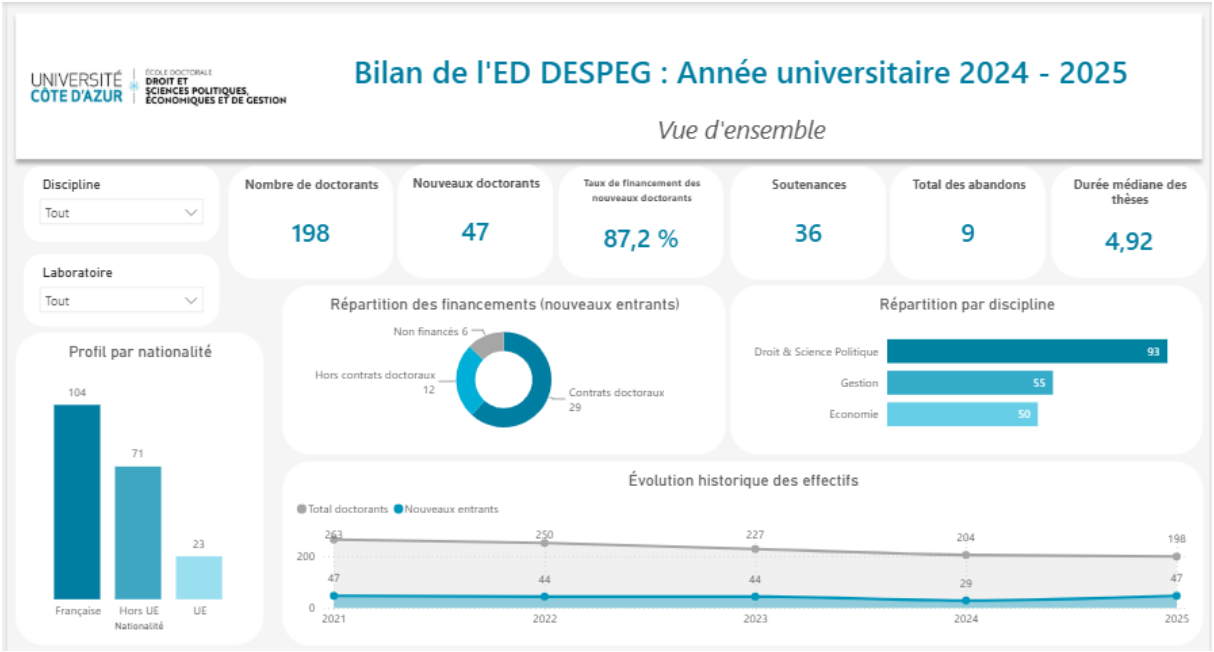


FIGURE 1 – Vue d'ensemble du tableau de bord "Statistiques Institutionnelles"

— **Soutenances et Abandons :** Analyse précise de la durée médiane des thèses (en années) et de la dynamique des départs, qui différencie les abandons notifiés des dépassements de délais (Voir Figure 9 dans l'annexes 5).

— **Parité et Historique :** Une vue dédiée à l'accès au financement et à la répartition des abandons par genre, complétée par un onglet retraçant l'évolution historique des effectifs et des taux clés sur les cinq dernières années(Voir Figure 10 et 11 dans l'annexes 5).

2. Le Tableau de Bord "Insertion Professionnelle" : Ce second rapport se concentre sur les devenirs professionnels des anciens doctorants enquêtés :

— **Vue d'ensemble :** Affichage des indicateurs majeurs tels que l'effectif total, le taux de réponses, le taux d'insertion global et la répartition par secteur d'activité.(Voir Figure 12 dans l'annexes 5)

— **Dynamique d'insertion :** Comparaison de l'évolution de la stabilité professionnelle (part d'emplois stables, part dans le secteur privé) à 1 an, 3 ans et 5 ans après la thèse (voir Figure 2 ci dessous).

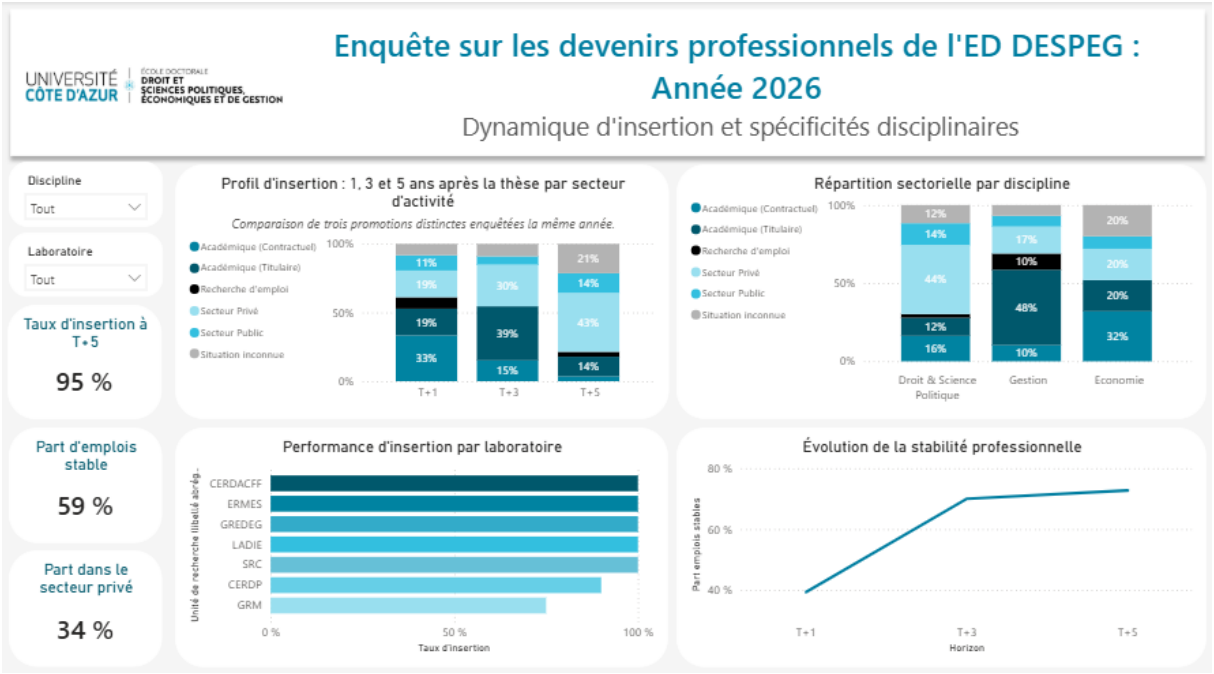


FIGURE 2 – Analyse de la dynamique d'insertion à T+1, T+3 et T+5

Afin de guider les gestionnaires et la direction dans l'interprétation de ces chiffres, l'expérience utilisateur a été renforcée par l'ajout d'infobulles interactives contenant des informations complémentaires, ainsi que par l'intégration d'une page "Glossaire" dans chaque tableau de bord, définissant strictement les règles de calcul de chaque indicateur. Enfin, pour répondre aux enjeux de confidentialité des données tout en assurant la communication institutionnelle, la diffusion sur le site web de l'école doctorale s'effectue via des exports PDF ou des captures d'écran statiques des vues filtrées, garantissant ainsi une "étanchéité" totale avec les bases de données sous-jacentes.

4) Passation, documentation et livrables finaux

Afin de gérer au mieux la fin de mon stage et de garantir que l'outil reste pleinement fonctionnel, la dernière phase de ma mission a été consacrée à la passation. L'enjeu principal était de rendre les membres de l'équipe totalement autonomes dans l'utilisation du pipeline et la mise à jour des tableaux de bord après mon départ.

Pour cela, j'ai rédigé et structuré une documentation complète, pensée pour deux publics distincts :

— **Documentation métier :** Un « GUIDE_UTILISATEUR » très visuel et détaillé pas-à-pas a été rédigé pour guider les gestionnaires dans l'exécution des routines mensuelles ou annuelles (génération des statistiques, gestion des "A vérifier"). Ce corpus est complété par un manuel de paramétrage pour l'outil de sondage (« Guide pour limesurvey ») et par des modèles de communication standardisés (ex : `Modèle_Mail_ancien_directeur.docx`) pour fluidifier l'enquête Alumni.

— **Documentation technique :** Un « Référentiel_Technique_de_l_Outils » a été produit pour documenter l'architecture ETL, le dictionnaire des données, l'écosystème de sécurité et les règles de gestion (DAX et Python). Ce livrable allant de pair avec mon code commenté, garantit la maintenabilité du code par d'éventuels futurs *Data Analysts* ou informaticiens de l'Université.

La phase de passation s'est matérialisée par l'installation physique des outils sur les postes de travail de l'École Doctorale, sécurisée par un « Guide d'installation de l'outil » dédié au déploiement de l'environnement Python portable et de Power BI. Pour accompagner cette transition technique, j'ai animé des sessions de formation pratiques en présentiel. Afin de démystifier le fonctionnement en arrière-plan du pipeline auprès d'un public non-développeur, j'ai également conçu et dispensé un module d'initiation au langage de programmation `Formation_python.html`.

Enfin, j'ai pu intégrer les tableaus de bord sur le site internet de l'ED DESPEG. En effet, disposant de droits d'édition avancés sur le CMS WordPress du site de l'Université Côte d'Azur, et suite à une formation dédiée au back-office, j'ai pu intervenir directement sur l'architecture web. J'ai notamment pris en charge la refonte technique et structurelle de pages stratégiques, comme celle dédiée à la mobilité internationale entrante. Cette polyvalence a permis de livrer un projet de bout en bout : de l'extraction de la donnée brute sur ADUM jusqu'à sa diffusion publique sur internet.

Conclusion de la Partie I

Cette mission au sein de l'École Doctorale DESPEG m'a permis de concevoir et de déployer un écosystème de données complet, transformant un environnement déclaratif fragmenté en un outil de pilotage stratégique automatisé et pérenne. En assumant ce rôle de *Data Analyst*, j'ai pu mettre en pratique et consolider mes compétences en ingénierie des données (Python), en *Business Intelligence* (Power BI) et en gestion de projet, tout en assurant l'accompagnement et la formation de l'équipe administrative.

Ce travail de fiabilisation et de structuration de la donnée brute constitue d'ailleurs le socle de toute analyse plus poussée. C'est précisément cette démarche de valorisation de l'informa-

tion qui fait le lien direct avec la seconde partie de ce mémoire. En effet, la conception de ce pipeline ETL n'a pas uniquement servi des objectifs de pilotage institutionnel : elle a fourni l'infrastructure technique indispensable à la réalisation de mon étude économétrique. J'ai pu réutiliser et adapter des modules entiers du code Python développé pour l'école, notamment la standardisation des clés de jointure (matricules), les algorithmes de nettoyage textuel et l'arbre décisionnel de classification des financements, afin de consolider les registres bruts d'ADUM en un panel anonymisé rigoureux. Ainsi, une fois la donnée nettoyer par la pipeline, il devients possible d'en faire une analyse académique sur les déterminants de l'achèvement de la thèse en trois ans, démarche qui fera l'objet de la suite de ce rapport.

Partie II : Étude économétrique des déterminants de l'achèvement de la thèse

A) Introduction

L'achèvement d'une thèse de doctorat représente un défi académique, personnel et professionnel majeur. Si la norme institutionnelle (le schéma LMD conduisant au grade de Bac+8) fixe la durée de référence du doctorat à trois années, la réalité des trajectoires étudiantes se révèle souvent beaucoup plus hétérogène. Comprendre les facteurs qui influencent le respect de ce calendrier standard constitue un enjeu de premier plan, tant pour les universités soucieuses d'optimiser l'accompagnement de leurs doctorants que pour les financeurs de la recherche.

Ce mémoire s'attache à identifier les déterminants individuels, académiques et matériels qui favorisent l'achèvement du parcours doctoral dans un délai strict de trois ans. Pour mener à bien cette analyse, notre étude se concentre sur le cas de l'École Doctorale DESPEG (Droit, Économie, Sciences Politiques et Gestion) de l'Université Côte d'Azur.

Afin de répondre à cette problématique, nous avons mobilisé les registres administratifs bruts issus de l'application ADUM, couvrant les inscrits des années universitaires 2020-2021 à 2024-2025. Un important travail d'ingénierie des données sous Python a permis de consolider ces informations en un panel anonymisé, puis de filtrer l'échantillon pour se concentrer sur les cohortes entrantes de 2019 à 2023, neutralisant ainsi les biais de censure et de troncature inhérents à l'observation de parcours longs. L'analyse économétrique, menée sur un échantillon final de 255 doctorants, s'appuie sur des modèles de choix qualitatifs (Moindres Carrés Ordinaires et Logit) particulièrement adaptés au traitement des événements rares.

Pour répondre à notre problématique, nous ferons tout d'abord une revue de la littérature existante (Section B), puis nous détaillerons le processus rigoureux de création et de structuration de la base de données (Section C). La Section D présentera la stratégie d'échantillonnage ainsi que les statistiques descriptives de notre cohorte. Enfin, la Section E exposera notre méthodologie économétrique et l'analyse critique de nos résultats concernant les déterminants de la soutenance en 3 ans.

B) Revue de littérature

L'analyse des déterminants de l'achèvement d'une thèse s'inscrit dans une littérature plus large portant sur l'économie de la science et la sociologie du monde académique. Pour cerner les facteurs influençant la durée et la réussite du parcours doctoral, il convient d'analyser le marché du travail académique, le rôle de l'environnement de recherche local, ainsi que l'impact de la structure de financement.

1) Un marché du travail académique sous tension

Le monde académique produit de plus en plus de doctorats à l'échelle mondiale, une expansion que Cyranoski et al. (2011) qualifient de véritable "PhD Factory". Cette surproduction, couplée à une stagnation des postes académiques titulaires, engendre un marché de l'emploi hyper-concurrentiel. Dans ce contexte, Cyranoski et al. (2011) et Corsini et al. (2022) mettent en évidence que la maximisation de la productivité scientifique devient un impératif stratégique pour espérer survivre académiquement.

2) L'impact de l'écosystème local : Encadrement et dynamique de groupe

La littérature démontre que le succès d'un doctorant dépend fortement de son écosystème de recherche. Corsini et al. (2022) prouvent, sur une vaste population de doctorants français, que les caractéristiques du directeur de thèse impactent directement la productivité de l'étudiant. Ils soulignent notamment qu'un encadrement par une chercheuse ou par un chercheur en milieu de carrière disposant de financements nationaux (ANR) est associé à de meilleures performances.

Par ailleurs, Broström (2019) démontre que la dynamique du laboratoire et la taille du groupe de pairs jouent un rôle critique : les doctorants évoluant avec un ratio plus faible d'étudiants par chercheur senior reussisent mieux en début de carrière. À l'inverse, un nombre trop élevé de pairs tend à pénaliser la productivité globale du groupe, probablement à cause de la dilution du temps d'encadrement et des coûts de coordination qui en découlent.

3) Le paradoxe du financement et l'adaptation des trajectoires

Enfin, la nature du financement conditionne l'orientation même de la thèse. Mangematin (2000) souligne que les trajectoires professionnelles doctorales sont peu flexibles et que les étudiants adaptent leur stratégie (publications académiques versus collaborations industrielles) dès le début de leur recherche selon le secteur ciblé.

Dans le prolongement de ces constats, Broström (2019) ajoute qu'un financement accordant un fort contrôle au financeur externe limite la productivité scientifique pure de l'étudiant, tout en favorisant son maintien en emploi. Cette littérature permet de mettre en perspective un phénomène de rétention stratégique : la sécurité offerte par un contrat doctoral classique peut paradoxalement inciter le doctorant à allonger la durée de sa thèse pour étoffer son dossier de publication face à un marché fermé, plutôt que de viser une diplomation stricte en trois ans.

En définitive, la littérature souligne que l'achèvement d'une thèse ne relève pas de la seule volonté ou des capacités individuelles du chercheur, mais résulte d'une combinaison complexe incluant son environnement matériel, son encadrement et les stratégies du marché du travail. Le type de financement, le genre, la spécialité et les dynamiques de laboratoire sont autant de paramètres qui modèlent la trajectoire doctorale. C'est précisément à la lumière de ces travaux que notre démarche empirique a été construite. Afin de vérifier si ces dynamiques macroécono-

miques et structurelles se confirment à l'échelle locale de l'École Doctorale DESPEG, la section suivante détaillera la création d'une base de données inédite, spécifiquement créé pour capturer l'ensemble de ces dimensions.

C) Création de la base de données

La qualité de l'analyse économétrique repose sur la fiabilité de la donnée initiale. Dans ce chapitre, nous détaillerons la création de la base de données en passant de la transformation des registres administratifs bruts de l'application ADUM à une base de données exploitable.

1) Centralisation des fichiers ADUM et anonymisation

Les données extraites couvrent les inscrits de l'École Doctorale DESPEG de l'année universitaire 2020-2021 à 2024-2025. Par souci de simplification lors du traitement des données, une convention d'encodage a été adoptée : chaque année universitaire est désignée par sa borne supérieure (par exemple, l'année 2020-2021 est codée « 2021 »). Pour structurer la base, la liste officielle des inscrits de chaque année a été utilisée comme fichier de base. Les autres fichiers thématiques (état civil, diplômes, thèses, financements) y ont ensuite été rattachés par des jointures successives. Cette méthode garantit que toutes les informations sont centralisées autour de la présence effective de l'étudiant, constituant ainsi un panel déséquilibré de suivi annuel.

Pour garantir des jointures sans perte, la clé primaire (le matricule étudiant) a été standardisée. Une fonction Python a été développée pour supprimer les espaces superflus et les décimales générées lors des imports. Conformément au RGPD, la base de données finale a été strictement anonymisée par la suppression des champs nominatifs (noms et prénoms), seul le matricule étant conservé pour permettre le suivi de l'étudiant dans le temps.

2) Ingénierie des variables et catégorisation des profils

L'unification des fichiers a nécessité un important travail de traitement de texte et de catégorisation sous Python pour construire le profil des étudiants. Par exemple, l'origine académique a été harmonisée par l'intermédiaire d'expressions régulières afin d'isoler les diplômes de Master obtenus à l'Université Côte d'Azur (UCA). Le traitement le plus complexe a concerné les libellés de financement dans ADUM, qui étaient très hétérogènes. Un nettoyage textuel a permis d'implémenter un arbre décisionnel de classification à plusieurs niveaux pour regrouper les situations en catégories normalisées (étudiant financé ou non, présence d'un contrat doctoral, etc.). Pour assurer la robustesse temporelle du panel, une propagation vers l'avant a été appliquée, couplée à un filtre de validité : un contrat n'est considéré comme actif sur l'année universitaire que si sa date de fin s'étend au-delà du 1er octobre. Enfin, la saisie des financements dans ADUM étant déclarative, certains libellés échappaient à la détection par mots-clés

du script Python. Pour ces observations, une vérification et une classification manuelles ont été réalisées afin de garantir l'exhaustivité et la fiabilité finale de la base de données.

À partir de ce panel consolidé, les indicateurs finaux introduits dans les modèles économétriques sous Stata ont été codés de la manière suivante :

— **La variable dépendante (*defenced_on_time*)** : Variable binaire égale à 1 si le doctorant a soutenu sa thèse à l'issue stricte de sa troisième année d'inscription, et 0 dans tous les autres cas.

— **Variables de contrôle individuelles** :

  — *female* : Binaire (1 pour les femmes).

  — *French* : Binaire (1 pour la nationalité française).

  — *age_entry* : Âge calculé au moment de l'inscription en première année.

— **Variables de contexte académique et matériel** :

  — *funding* : Binaire (1 si l'étudiant dispose d'un financement doctorale : si le deuxieme niveau de catégorisation de financement est égal à contract doctoral).

  — *from_uca* : Binaire (1 si le Master d'origine a été obtenu à l'UCA).

  — *management* : Binaire isolant la spécialité en Sciences de Gestion. Les disciplines du Droit, de la Science Politique et des Sciences Économiques forment le groupe de référence implicite (ce regroupement évite les biais de séparation parfaite, les données ne recensant aucune soutenance en 3 ans en Économie).

3) Identification des trajectoires de sortie

Les données annuelles ont été croisées avec les bases de soutenances pour repérer l'aboutissement des parcours. Pour ces étudiants diplômés, la durée de thèse, initialement extraite en mois, a été convertie en années afin de fournir un indicateur de cadrage sur les temps de diplomation globaux.

Cependant, pour modéliser correctement la survie dans le cursus, il était crucial d'identifier les abandons, qui sont souvent non déclarés par les doctorants.Pour cela nous nous basons sur la « dernière année visible » de l'étudiant dans le panel pour qualifier ces sorties définitives sans soutenance. Elles sont classées en trois catégories : les arrêts officiellement déclarés, les interruptions de fait (disparition des listes de réinscription d'une année sur l'autre), et les délais maximaux atteints (étudiants inscrits en sixième année ou plus avec un commentaire administratif de refus de dérogation).

D) Echantillonnage et statistiques descriptives

À l'issue de la préparation des données, il est indispensable de définir précisément le périmètre temporel de l'étude. Ce chapitre a pour objectif de construire notre cohorte d'analyse

en retirant les biais d'observation inhérents au suivi de parcours longs, puis de dresser le profil statistique de notre base finale.

1) Stratégie d'échantillonnage et transformation des données

L'analyse de la durée des parcours doctoraux peut être confrontée à des biais statistiques liés à l'observation des données dans le temps. Pour garantir la validité de nos estimations, une restriction stricte de l'échantillon a été opérée. L'étude se concentre exclusivement sur les cohortes d'étudiants inscrits en première année entre les années universitaires 2018-2019 et 2022-2023 (soit les cohortes 2019 à 2023).

Ce calibrage temporel permet de neutraliser deux biais économétriques majeurs :

— **Le biais de troncature à gauche** : Conserver les doctorants ayant débuté leur thèse avant la cohorte 2019 dans un panel observé à partir de la cohorte 2021 reviendrait à surreprésenter artificiellement les thèses longues. En effet, seuls les doctorants n'ayant pas réussi à soutenir en trois ans seraient encore présents dans nos registres récents (effet de sélection par la survie).

— **Le biais de censure à droite** : À l'inverse, les doctorants entrés en 2024 et 2025 ont été exclus de l'échantillon d'analyse, car il est physiquement impossible d'observer l'issue de leur parcours à l'horizon de trois ans, leur délai réglementaire n'étant pas encore écoulé.

Une fois ces cohortes complètes isolées, la base de données nécessitait une ultime transformation. Bien que la base consolidée soit structurée sous forme de panel déséquilibré (un suivi année par année de l'étudiant), notre problématique ne porte pas sur les transitions infra-annuelles, mais sur l'aboutissement final de la trajectoire. Par conséquent, la dimension temporelle du panel a été compressée à l'aide d'un opérateur d'agrégation (*collapse*). Cette opération convertit la base en une coupe transversale (*cross-section*), où chaque doctorant n'est plus représenté que par une observation unique synthétisant ses caractéristiques invariantes et son statut final de diplomation à l'horizon T+3.

2) Statistiques descriptives de l'échantillon

Avant de procéder à l'analyse économétrique, il convient de présenter les caractéristiques principales de notre échantillon d'analyse. Le Tableau 1 synthétise les statistiques descriptives des 255 doctorants composant notre base finale.

TABLE 1 – Statistiques descriptives de l'échantillon d'analyse

Variable	Moyenne	Écart-type	Min	Max
Soutenance en 3 ans	0.055	0.228	0	1
Femme	0.471	0.500	0	1
Nationalité Française	0.486	0.501	0	1
Âge à l'inscription	30.204	7.471	23	69
Spécialité Gestion	0.302	0.460	0	1
Contrat doctoral	0.439	0.497	0	1
Master origine UCA	0.549	0.499	0	1
N	**255**			

Le premier constat frappant concerne notre variable d'intérêt : l'achèvement de la thèse dans le délai réglementaire strict de trois ans constitue un événement rare au sein de l'École Doctorale DESPEG, concernant seulement 5,5% de la cohorte étudiée.

Concernant le profil sociodémographique, l'échantillon affiche une proportion de femmes de 47,1% et est composé à 48,6% d'étudiants de nationalité française. L'âge moyen lors de l'inscription en première année s'établit à 30,2 ans. Toutefois, comme l'illustre la Figure 3, cette moyenne masque une forte asymétrie de la distribution : on observe une concentration majeure de doctorants âgés de 24 à 27 ans (inscrits en continuité directe de leur Master), coexistant avec une longue traîne de profils plus âgés (jusqu'à 69 ans), caractéristiques des reprises d'études ou des parcours professionnels.

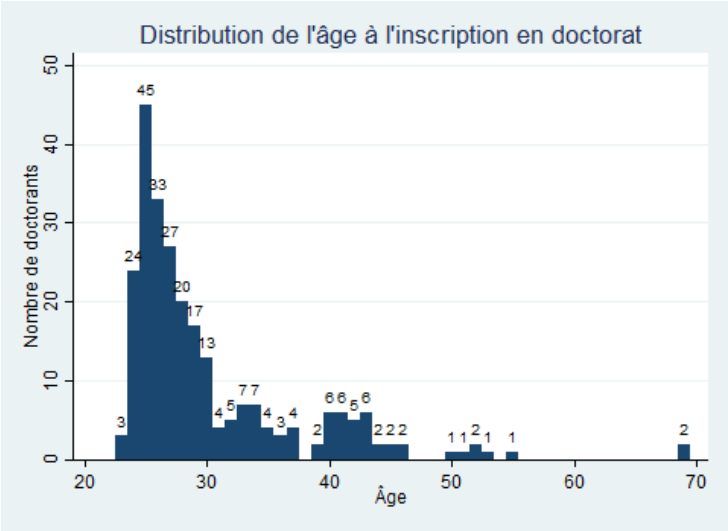


FIGURE 3 – Distribution de l'âge à l'inscription en doctorat

Sur le plan académique et matériel, la spécialité en Sciences de Gestion représente 30,2% des inscrits, et plus de la moitié des doctorants (54,9%) ont obtenu leur diplôme de Master au

sein de l'Université Côte d'Azur (UCA). Par ailleurs, 43,9% des doctorants de l'échantillon bénéficient d'un contrat doctoral.

Enfin, une première observation des données brutes permet de mettre en lumière d'importantes hétérogénéités de trajectoire. En effet, on constate que 10% des doctorantes de notre échantillon ont soutenu en trois ans, contre seulement 1,48% de leurs homologues masculins. De même, la spécialité d'inscription semble clivante, avec un taux de soutenance dans les délais de 10,39% en Gestion, contre 3,37% pour les autres disciplines (sachant qu'en Économie il n'y a aucun doctorant ayant soutenu en 3 ans). De manière plus contre-intuitive, le taux de diplomation en trois ans n'est que de 2,68% pour les bénéficiaires d'un contrat doctoral, contre 7,69% pour les autres profils. L'analyse économétrique développée dans la section suivante s'attachera justement à vérifier si ces disparités brutes se traduisent par de véritables effets toutes choses égales par ailleurs.

TABLE 2 – Matrice de corrélation

	Soutenu	**Femme**	**Français**	**Âge**	**Gestion**	**Contrat**	**Master UCA**
Soutenu	1						
Femme	0.1867*	1					
Français	0.0066	0.0573	1				
Âge	0.0927	-0.0764	-0.0740	1			
Gestion	0.1415*	0.0987	-0.1614*	0.1550*	1		
Contrat	-0.1090	0.1313*	0.2298*	-0.3326*	0.0031	1	
Master UCA	-0.0583	0.0492	0.3457*	-0.1020	0.0468	0.1828*	1

* $p < 0.05$

Avant de procéder à cette modélisation, la présentation de la matrice de corrélation (Tableau 2) permet de vérifier l'absence de problèmes de multicolinéarité entre nos variables explicatives. L'analyse de cette matrice indique que les coefficients inter-variables demeurent tous à des niveaux très modérés. La corrélation la plus forte s'établit à 0,3457 entre la nationalité française et l'obtention du Master à l'UCA, suivie par une corrélation négative de -0,3326 entre l'âge à l'inscription et le bénéfice d'un contrat doctoral. Ces niveaux étant largement inférieurs aux seuils critiques habituels, cela écarte un risque majeur. De plus, cette matrice vient appuyer nos premières observations bivariées : l'achèvement de la thèse en trois ans (variable Soutenu) est positivement et significativement corrélé avec le fait d'être une femme (0,1867) et d'être inscrit en spécialité Gestion (0,1415).

E) Méthodologie et Résultats

L'objectif empirique de ce mémoire est d'identifier les déterminants individuels, académiques et matériels qui favorisent l'achèvement du parcours doctoral dans le délai réglemen-

taire de trois ans. Ce chapitre détaille la stratégie économétrique mise en œuvre pour traiter cette problématique et présente l'analyse critique des résultats obtenus.

1) Méthodologie Économétrique

Le choix de notre méthode d'estimation est directement dicté par la nature de notre variable à expliquer. Notre variable dépendante d'intérêt (*defenced_on_time*) étant une variable dichotomique prenant la valeur 1 si l'étudiant a soutenu à l'issue stricte de sa troisième année, et 0 sinon, l'estimation de ses déterminants requiert l'utilisation de modèles de choix qualitatifs. Notre démarche repose ainsi sur l'estimation comparative de deux modèles :

— **L'estimation par les Moindres Carrés Ordinaires (MCO)** : Utilisée comme première étape exploratoire, la régression linéaire classique nous permet de construire un modèle de référence dit « naïf ». Le modèle se formalise ainsi :

$$\begin{aligned} Y_i = &\beta_0 + \beta_1 \text{Femme}_i + \beta_2 \text{Français}_i + \beta_3 \hat{\text{A}}\text{ge}_i + \beta_4 \text{Gestion}_i \\ &+ \beta_5 \text{Contrat}_i + \beta_6 \text{UCA}_i + \sum \gamma_t \text{Cohorte}_t + \varepsilon_i \end{aligned} \tag{1}$$

Nous l'utilisons pour son principal avantage : la lecture directe de ses résultats. Les coefficients fournissent une approximation immédiate de l'effet des variables explicatives sur la probabilité de soutenir en trois ans. Toutefois, ce modèle présente des limites connues (hétéroscédasticité des résidus et risque de prédire des probabilités en dehors de l'intervalle [0, 1]). Les MCO servent donc uniquement de point de départ.

— **Le modèle Logit** : Pour pallier les limites de l'estimation linéaire, nous mobilisons un modèle logistique estimé par la méthode du Maximum de Vraisemblance. La probabilité qu'un doctorant soutienne en 3 ans ($Y_i = 1$) est modélisée par une fonction logistique :

$$P(Y_i = 1|X_i) = \frac{\exp(X_i\beta)}{1+\exp(X_i\beta)} \tag{2}$$

Où X_i représente le vecteur des variables explicatives. Le modèle Logit est particulièrement pertinent dans notre cadre d'étude pour deux raisons. D'une part, il contraint mathématiquement les probabilités prédites entre 0 et 1. D'autre part, il est particulièrement adapté au traitement des événements dits « rares ». Les statistiques descriptives de notre échantillon révèlent en effet que la soutenance stricte en trois ans ne concerne qu'environ 5,5% de la population étudiée, justifiant le recours à une spécification non linéaire pour capturer finement les effets dans les queues de distribution.

2) Résultats

TABLE 3 – Déterminants de la soutenance en trois ans

Variables	**MCO**	**Logit**
Femme	0.091***	2.161***
	(0.002)	(0.007)
Nationalité Française	0.038	0.784
	(0.224)	(0.244)
Cohorte 2020	-0.002	-0.193
	(0.963)	(0.822)
Cohorte 2021	-0.069*	-1.851
	(0.098)	(0.119)
Cohorte 2022	-0.035	-0.696
	(0.418)	(0.461)
Cohorte 2023	-0.006	-0.094
	(0.891)	(0.912)
Âge à l'entrée	0.001	0.013
	(0.530)	(0.701)
Spécialité Gestion	0.070**	1.372**
	(0.030)	(0.035)
Financement dédié (Contrat)	-0.058*	-1.415*
	(0.065)	(0.063)
Master origine UCA	-0.037	-0.827
	(0.221)	(0.221)
Constante	0.001	-4.383***
	(0.986)	(0.002)
Observations	255	255
R-carré / Pseudo R-carré	0.090	0.2227

p-values entre parenthèses. * $p < 0.10$, ** $p < 0.05$, *** $p < 0.01$

Le Tableau 3 présente les résultats de nos estimations visant à identifier les déterminants d'une soutenance de thèse en trois ans. Les résultats issus du modèle linéaire (MCO) et du modèle logistique (Logit) affichent de la cohérence dans le signe et la significativité des coefficients, ce qui témoigne d'une certaine robustesse de nos spécifications face à un événement rare

(5,5%). L'analyse de ces résultats met tout d'abord en évidence une différence de trajectoire très marquée selon le genre des doctorants. En effet, la variable Female présente un coefficient positif et hautement significatif, au seuil de 1%, dans les deux modèles. L'estimation par les MCO indique ainsi que, toutes choses égales par ailleurs, le fait d'être une femme augmente la probabilité de soutenir sa thèse dans les délais réglementaires de 9,1 points de pourcentage par rapport aux hommes au sein de l'École Doctorale DESPEG.

Afin d'approfondir la compréhension de cet effet de genre, nous avons cherché à savoir si un appariement de genre (*gender-matching*) entre le doctorant et la direction de thèse jouait un rôle favorable. L'introduction d'une variable d'interaction croisant le genre féminin de l'étudiante et celui de la direction (présentée dans le Tableau 4 en Annexe 6) ne révèle cependant aucun effet conjoint significatif, la *p-value* associée étant supérieure à 0,90. L'avantage observé pour les doctorantes ne dépend donc pas du genre de leur encadrant. Cette spécification alternative ayant par ailleurs dégradé la significativité globale des effets principaux, elle n'a logiquement pas été conservée dans notre modèle de référence.

Au-delà des caractéristiques démographiques, le contexte académique joue un rôle crucial dans le respect du calendrier doctoral. La spécialité de recherche s'avère être un déterminant majeur, comme l'illustre le coefficient positif et significatif (au seuil de 5%) de la variable Management. Les doctorants inscrits en Sciences de Gestion ont une probabilité de soutenir en trois ans supérieure d'environ 7 points de pourcentage par rapport au groupe de référence, composé du Droit, des Sciences Économiques et de la Science Politique. Cet écart peut refléter des différences structurelles profondes entre les disciplines, qu'il s'agisse des exigences de publication, de la culture des laboratoires ou de la nature des travaux de recherche.

Le résultat le plus étonnant de notre modèle réside dans l'analyse de l'impact du financement. En isolant les doctorants bénéficiant d'un « Contrat doctoral » (catégorie regroupant les contrats académiques classiques et les conventions CIFRE), nos résultats révèlent un effet négatif et significatif au seuil de 10%. Il est important de rappeler que cet effet s'interprète par rapport au groupe de référence, qui rassemble ici les doctorants non financés et ceux exerçant une activité professionnelle principale. Ce résultat, en apparence contre-intuitif, pourrait s'expliquer par des comportements et des contraintes divergeants selon les profils. D'une part, les doctorants non financés ou professionnels pourraient être incités à finaliser leur parcours le plus rapidement possible en raison de contraintes financières ou d'objectifs de progression de carrière immédiats. D'autre part, un étudiant disposant d'un contrat doctoral pourrait faire le choix de prolonger ses travaux d'une année supplémentaire (par exemple en s'appuyant sur un poste d'ATER) afin d'être plus pointilleux sur ses recherches, d'en maximiser la qualité et d'étoffer son dossier de publications pour le marché du travail académique, comme le suggère Broström (2019). Le contrat doctoral n'induirait donc pas systématiquement une soutenance plus rapide, mais offrirait plutôt une marge de manœuvre afin de l'allonger stratégiquement.

Enfin, il convient de souligner l'absence d'effet statistique de plusieurs variables de contrôle. Ni l'âge à l'inscription (*age_entry*), ni les effets fixes de cohorte (*entry_year*), ni l'origine du

Master (*from_uca*) ne modifient significativement la probabilité de soutenir dans les délais. De même pour la nationalité (*French*) : bien que la mobilité internationale implique naturellement des défis supplémentaires, nos résultats suggèrent que les contraintes réglementaires strictes liées au renouvellement des visas et des titres de séjour peuvent forcer les doctorants étrangers à respecter scrupuleusement l'échéance des trois ans, compensant ainsi d'éventuelles difficultés d'intégration institutionnelle.

F) Conclusion

Cette analyse économétrique s'est attachée à identifier les déterminants de l'achèvement d'une thèse en trois ans au sein de l'École Doctorale DESPEG. L'étude d'une cohorte de 255 doctorants révèle que le respect de ce délai institutionnel demeure un événement rare, circonscrit à 5,5% des effectifs. Nos modélisations mettent en évidence des disparités structurelles fortes : toutes choses égales par ailleurs, le fait d'être une femme augmente de 9,1 points de pourcentage la probabilité de soutenir à temps. Fait intéressant, cet avantage féminin est indépendant du genre de la direction de thèse, l'appariement de genre (*gender-matching*) n'ayant aucun effet conjoint significatif. Les inscrits en Sciences de Gestion affichent également une probabilité de soutenance dans les délais significativement supérieure.

Le résultat le plus contre-intuitif de cette étude, bien qu'en résonance avec la littérature récente, réside dans l'effet du contrat doctoral. Plutôt que d'accélérer la diplomation, ce financement dédié tend à l'allonger. Ce constat suggère l'existence d'un ralentissement stratégique : la sécurité financière offre aux doctorants la marge de manœuvre nécessaire pour prolonger leurs travaux et maximiser leurs publications en vue d'un marché du travail académique très compétitif.

Pour l'École Doctorale DESPEG, l'apport concret de ce travail est d'offrir une cartographie objective des trajectoires. Savoir que le contrat doctoral allonge statistiquement la thèse permet de mieux anticiper les flux de soutenances et de dédramatiser le dépassement des trois ans pour ces profils.

Toutefois, cette étude présente certaines limites. La taille restreinte de l'échantillon limite l'utilisation de modèles non-linéaires plus complexes, et la nature déclarative de certaines saisies dans ADUM requiert une prudence interprétative. De plus, des variables inobservables décisives telles que la motivation intrinsèque des étudiants, le temps exact consacré aux tâches annexes ou la qualité relationnelle de l'encadrement ne sont pas capturées. Une piste d'amélioration pour de futurs travaux consisterait à enrichir ce panel par des enquêtes qualitatives ou à étendre l'analyse aux autres écoles doctorales de l'Université Côte d'Azur afin d'éprouver la validité externe de ces résultats.

Conclusion Générale

Ce stage au sein de l'École Doctorale DESPEG a constitué une étape charnière, tant sur le plan du développement technique que dans l'affirmation de mon projet professionnel. La mission qui m'a été confiée a permis de répondre à un besoin institutionnel : transformer un système de stockage de données purement déclaratif en un outil de pilotage stratégique automatisé. Le développement et le déploiement du pipeline ETL sous Python, couplés aux tableaux de bord sur Power BI, ont doté la direction d'un outil pérenne pour suivre ses effectifs et l'insertion de ses diplômés.

Au-delà de la réponse au besoin métier, ce travail d'ingénierie a constitué le socle d'une démarche de recherche plus poussée. La fiabilisation des registres administratifs m'a offert l'opportunité d'initier une étude économétrique sur les déterminants de l'achèvement de la thèse. L'analyse a révélé que la soutenance en trois ans reste une exception (5,5 %), favorisée par le genre féminin et l'inscription en Sciences de Gestion, mais ralentie de manière contre-intuitive par le bénéfice d'un contrat doctoral. Cette complémentarité illustre parfaitement le fait qu'il ne peut y avoir d'analyse statistique pertinente sans un travail rigoureux de nettoyage et de structuration des données en amont.

Sur le plan personnel, cette immersion a eu un impact décisif. Si mon projet initial s'orientait plutôt vers l'enseignement, l'autonomie dont j'ai bénéficié lors de ce stage a agi comme un véritable révélateur. J'ai énormément apprécié le fait de travailler avec un objectif métier précis, les différents problèmes rencontrés tout au long du développement ont été particulièrement stimulants, et il a été très gratifiant de pouvoir mettre mon savoir-faire au service d'un cas concret et utile. Tous ces aspecst de mon stage m'ont passionné. Cette expérience clôt ainsi mon cursus en confirmant définitivement ma volonté d'évoluer dans les métiers de la Data.

Bibliographie

Articles académiques

Broström, A., 2019. “Academic breeding grounds : Home department conditions and early career performance of academic researchers”. *Research Policy*, vol. 48, pp. 1647-1665.[cite : 6]

Corsini, A., Pezzoni, M., Visentin, F., 2022. “What makes a productive Ph.D. student ?”. *Research Policy*, vol. 51.[cite : 10]

Cyranoski, D., Gilbert, N., Ledford, H., Nayar, A., Yahia, M., 2011. “Education : The PhD factory”. *Nature*, vol. 472, pp. 276-279.[cite : 9]

Mangematin, V., 2000. “PhD job market : professional trajectories and incentives during the PhD”. *Research Policy*, vol. 29, pp. 741-756.[cite : 8]

Documentation technique et outils de développement

CustomTkinter (Création d’interfaces graphiques modernes et responsives en Python) : https://customtkinter.tomschimansky.com/

Unicodedata (Norme de traitement des chaînes de caractères et nettoyage typographique) : https://docs.python.org/3/library/unicodedata.html

XlsxWriter (Génération de fichiers Excel avancés, menus de validation et formatage conditionnel) : https://xlsxwriter.com/

NumPy (Vectorisation et traitement de conditions multiples via `np.select`) : https://numpy.org/doc/stable/reference/generated/numpy.select.html

Pandas (Manipulation de DataFrames et fonctions `.str` pour l’harmonisation de texte) : https://pandas.pydata.org/docs/

LimeSurvey - [Blog T.I.M. : Tutos LimeSurvey] : https://www.youtube.com/playlist?list=PLT22zthn8ytxARu602na6rEoK0R_ivIru

WordPress - [WordPress : Créer un SITE de A à Z - Formation 2026 (Gratuit)] : https://www.youtube.com/watch?v=y6zM7EeTRNA*

Intelligence Artificielle (LLM) : Utilisation d’un modèle de langage (Gemini) en tant qu’assistant de développement (débogage et optimisation des scripts Python) et support à l’intégration typographique sous LaTeX.

Annexes

Annexe 1 : Architecture globale et Diagramme de processus ETL

Ce logigramme détaille le cycle de vie complet de la donnée au sein de l'application développée pour l'ED DESPEG. Il illustre l'orchestration des flux entre l'ingestion des bases brutes (ADUM), la phase de traitement et d'audit métier (nettoyage et génération des matrices de saisie), jusqu'à la certification finale et l'historisation des données dans Microsoft Power BI. Ce processus met en évidence les différents boucliers de sécurité préventifs implémentés pour éviter toute corruption des données.

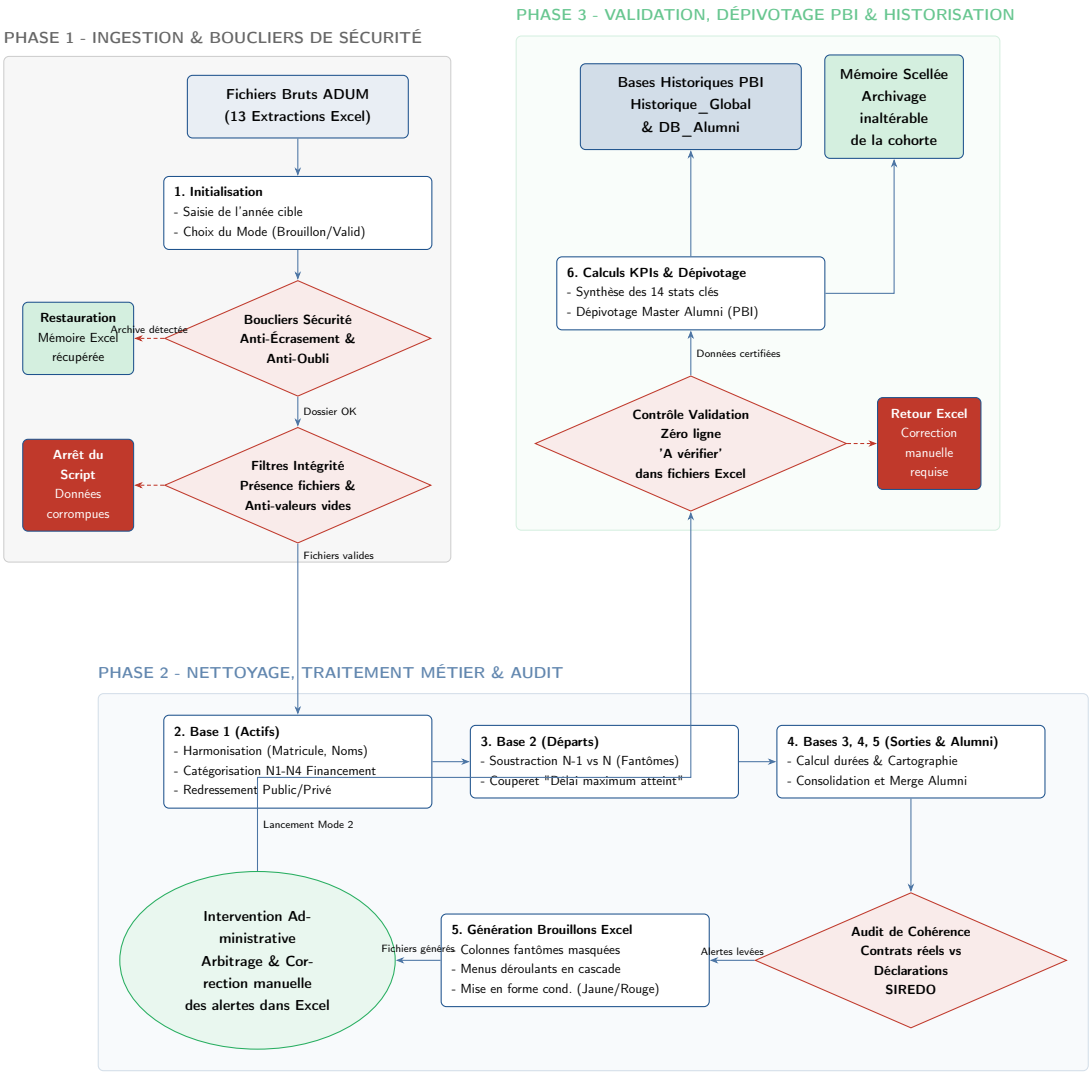


FIGURE 4 – Logigramme de l'architecture ETL développée sous Python

Annexe 2 : Arbre de décision de la taxonomie des financements

Cet arbre de décision illustre la nomenclature codée dans l'algorithme Python pour classifier automatiquement les sources de financement déclarées par les doctorants. Il permet de transformer des textes libres hétérogènes en catégories standardisées (N1 à N4), indispensables à l'analyse économétrique.

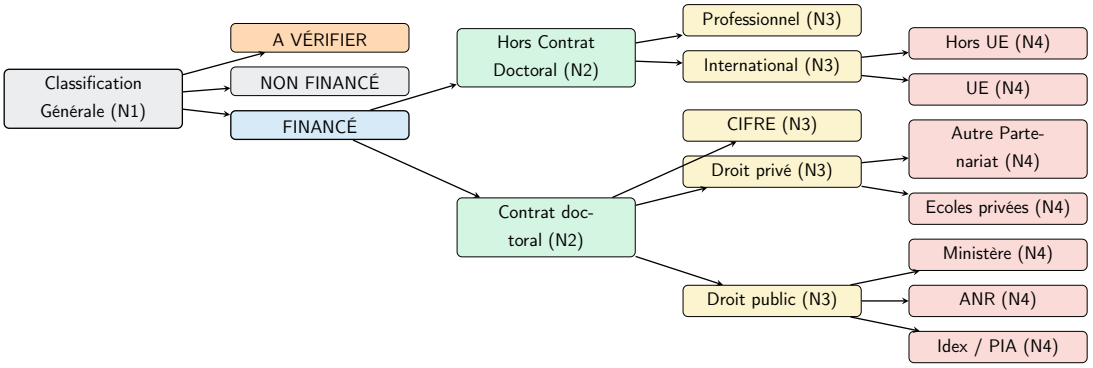


FIGURE 5 – Classification des types de financements de la thèse

Annexe 3 : Modélisation et traitement des départs

Afin d'étudier la survie dans le cursus doctoral, cet algorithme de qualification des sorties permet de dissocier les abandons formellement déclarés des simples disparitions administratives (interruptions de fait). Le "couperet temporel" garantit par ailleurs qu'un étudiant dépassant la limite légale des 6 ans sans dérogation soit techniquement considéré comme ayant échoué à soutenir.

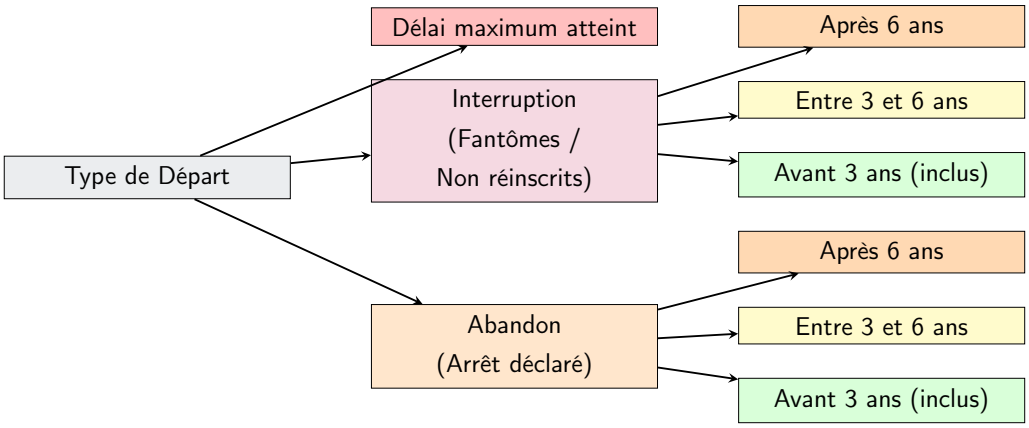


FIGURE 6 – Arbre décisionnel de traitement des trajectoires d'abandon

Annexe 4 : Typologie de l'insertion professionnelle post-thèse

Ce dernier schéma présente la segmentation appliquée pour analyser le devenir professionnel des Alumni (à T+1, T+3, et T+5). Cette catégorisation permet d'isoler avec précision le type de contrat (Titulaire vs Contractuel) et le secteur d'activité, facilitant la lecture des tableaux de bord Power BI.

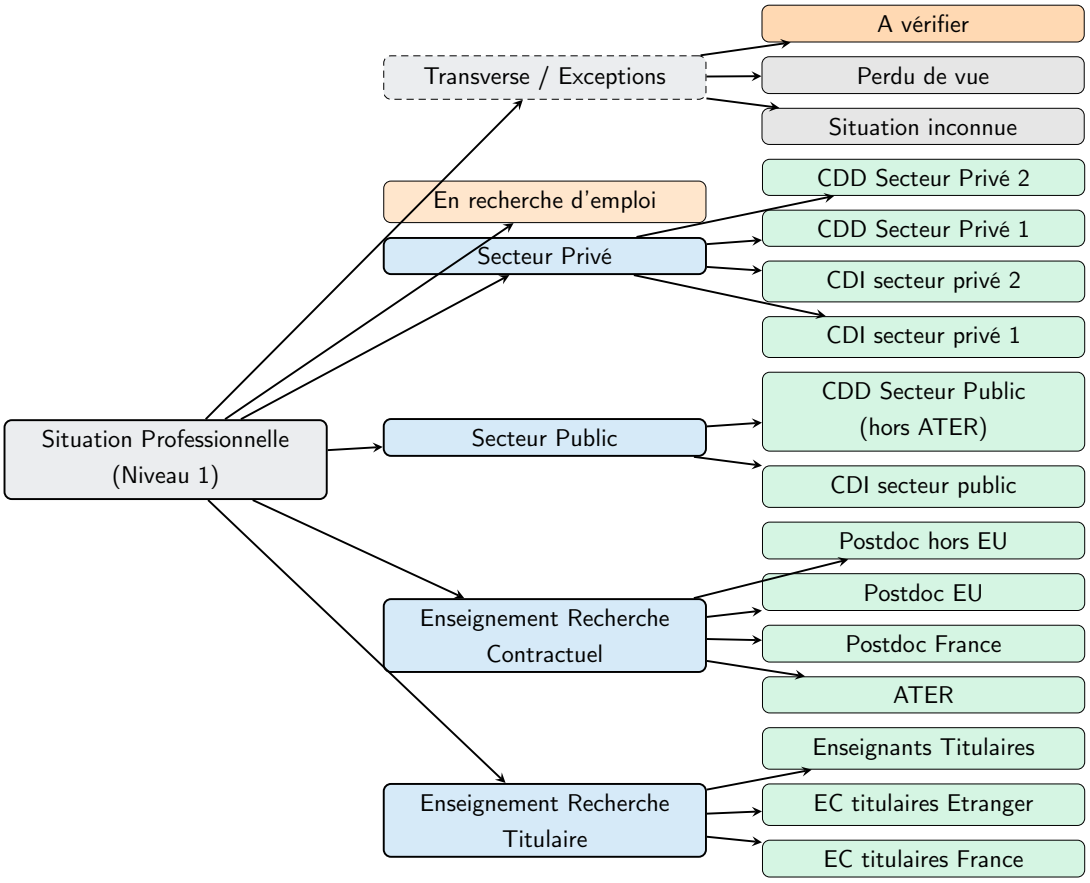


FIGURE 7 – Classification hiérarchique de l'insertion professionnelle

Annexe 5 : Vues complémentaires des tableaux de bord Power BI

Les captures d'écran ci-dessous présentent des vues additionnelles des rapports interactifs développés sous Microsoft Power BI. Elles illustrent la diversité des axes d'analyse mis à la disposition de la direction de l'École Doctorale (historique des effectifs, filtres par laboratoire, etc.).

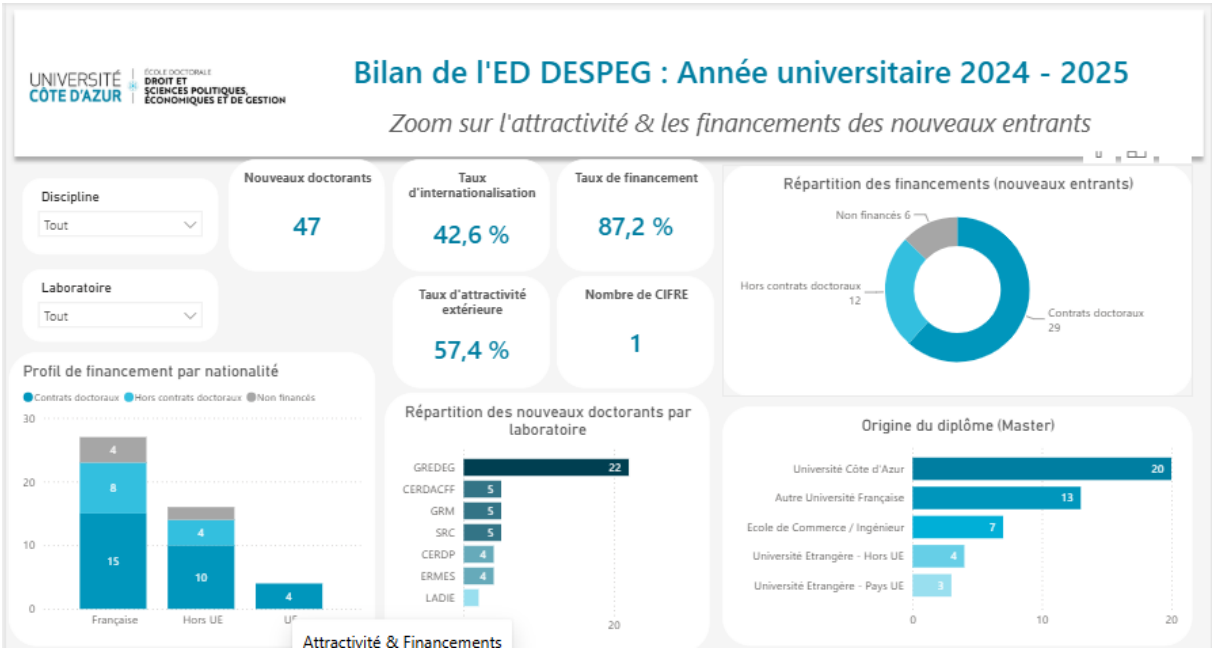


FIGURE 8 – Attractivité et financement des nouveaux entrants

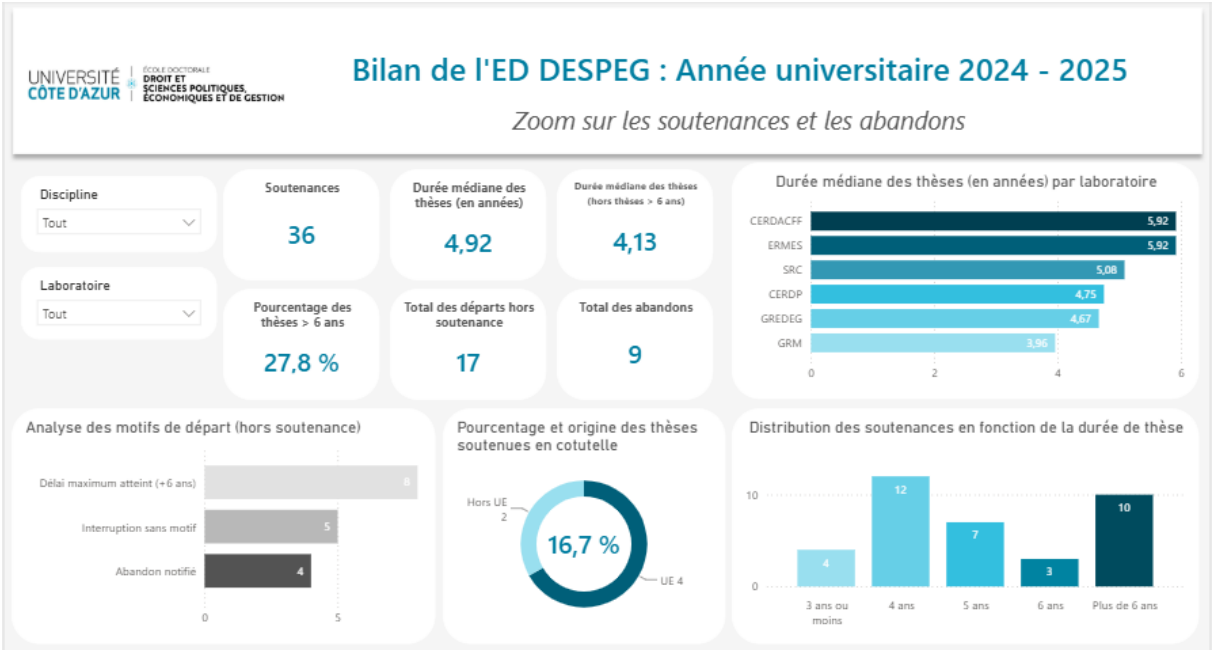


FIGURE 9 – Soutenances et abandons

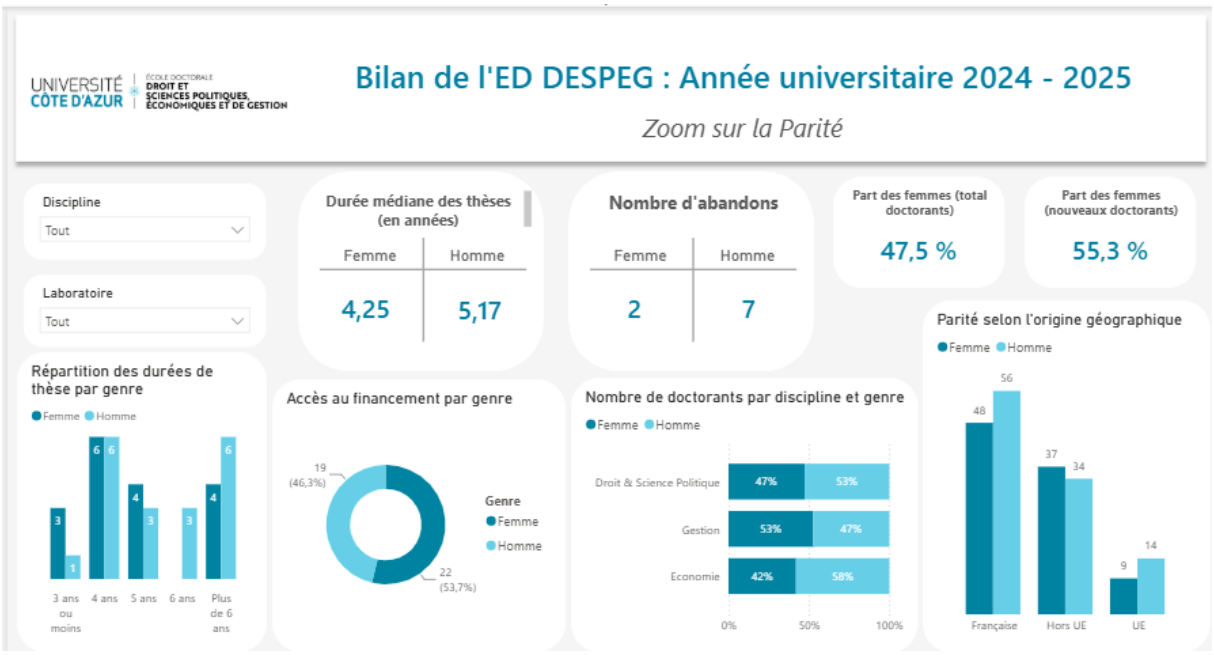


FIGURE 10 – Parité

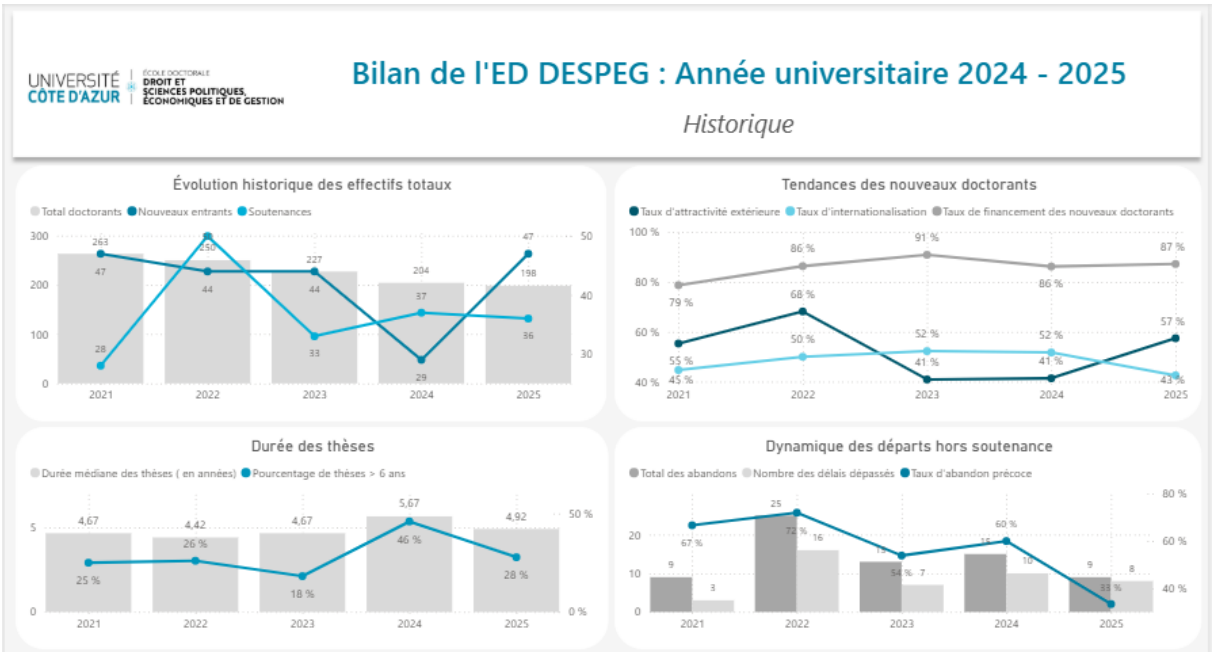


FIGURE 11 – Historique

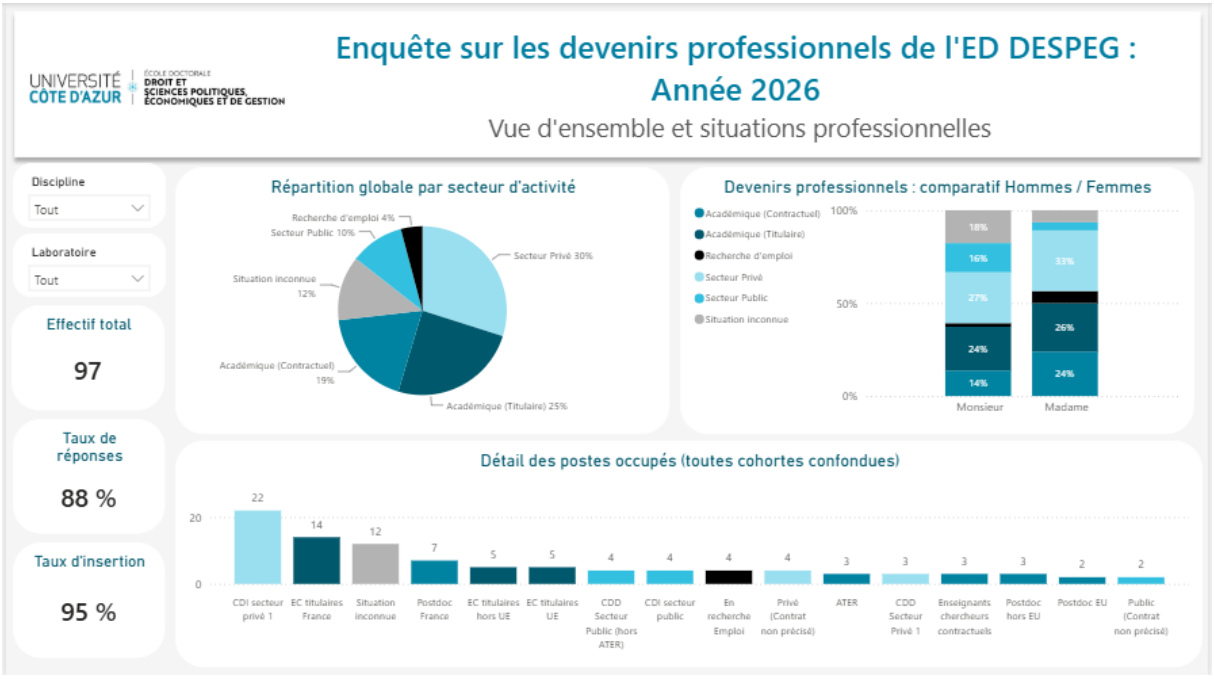


FIGURE 12 – Vue d'ensemble de la situations professionnelles

Annexe 6 : Déterminants de la soutenance en trois ans avec variable d'interaction

TABLE 4 – Déterminants de la soutenance en trois ans avec variable d'interaction

Variables	**MCO**	**Logit**
Femme	0.072*	2.057*
	(0.054)	(0.071)
Directrice de thèse	-0.009	-0.015
	(0.823)	(0.992)
Femme * Directrice	0.043	0.191
	(0.460)	(0.905)
Nationalité Française	0.037	0.774
	(0.242)	(0.260)
Cohorte 2020	-0.003	-0.227
	(0.944)	(0.795)
Cohorte 2021	-0.069	-1.810
	(0.103)	(0.130)
Cohorte 2022	-0.036	-0.702
	(0.408)	(0.458)
Cohorte 2023	-0.005	-0.087
	(0.904)	(0.918)
Âge à l'entrée	0.001	0.014
	(0.491)	(0.678)
Spécialité Gestion	0.065*	1.324*
	(0.051)	(0.054)
Financement dédié	-0.058*	-1.397*
	(0.066)	(0.067)
Master origine UCA	-0.039	-0.854
	(0.206)	(0.216)
Constante	0.003	-4.377***
	(0.966)	(0.005)
Observations	255	255
R-carré	0.093	

*p-values entre parenthèses. * $p < 0.10$, ** $p < 0.05$, *** $p < 0.01$*