Le Référentiel Techniquede l'outils

Architecture ETL, Dictionnaire des Données & Sécurités Système

Auteur : Thibault PHILIBERT
Concepteur de l'outil - Master 2 Expertise et Analyse des Données

Juin 2026

Cadre Méthodologique

Ce document consigne les spécifications techniques et fonctionnelles de la pipeline de traitement de données développée pour l'École Doctorale Économie, Gestion, Droit et Science Politique (ED DESPEG). L'application automatise la collecte, le nettoyage, l'audit de cohérence et l'historisation des données longitudinales des doctorants.

Table des matières

1 Architecture Globale et Écosystème Sécurisé **2**
1.1 Cartographie Physique (L'Arborescence Matricielle) . . . 2
1.2 L'écosystème de Sécurité (Les Garde-Fous Système) . . . 2

2 Orchestration des Flux : Les Deux Modules ETL **2**
2.1 Module 1 : Statistiques et Effectifs (Campagne de Printemps) . . . 2
2.2 Module 2 : Insertion Professionnelle & Alumni (Campagne d'Été) . . . 3

3 Diagramme de Processus Logiciel **4**

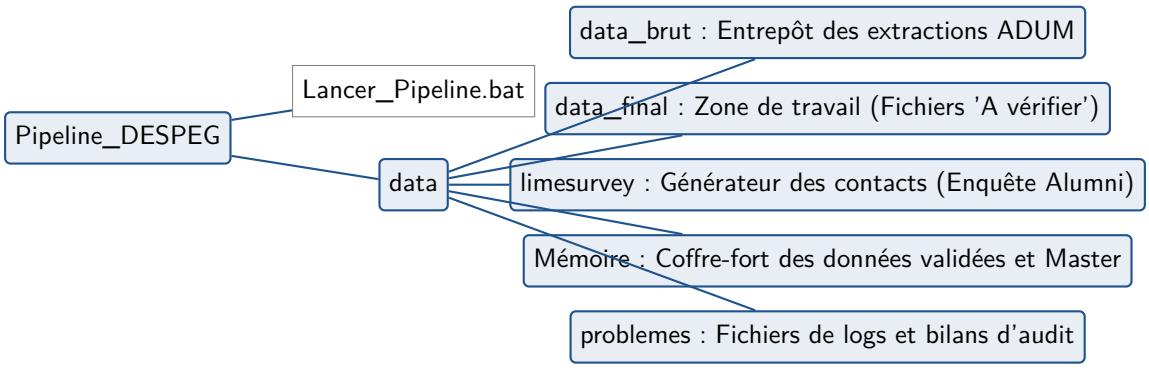
4 Dictionnaire des Données **6**
4.1 BASE 1 : Les Actifs (Nouveaux Entrants) . . . 6
4.2 BASE 2 : Les Départs (Abandons & Interruptions) . . . 6
4.3 BASE 3 : Les Soutenances . . . 7
4.4 BASE 4 : Le Registre des Effectifs Globaux . . . 7
4.5 BASE 5 : Le Suivi Alumni (Insertion Professionnelle) . . . 8

1. Architecture Globale et Écosystème Sécurisé

L'application développée ne se limite pas à un simple script de traitement de données : elle a été pensée et structurée comme un véritable progiciel ETL (Extract, Transform, Load) robuste. Le code s'articule autour de trois piliers fondamentaux : une interface graphique centralisée, une gestion physique stricte des flux de données (l'arborescence) et un bouclier de sécurités préventives (Anti-crash, Anti-erreur humaine).

1.1. Cartographie Physique (L'Arborescence Matricielle)

Le moteur Python interagit avec une structure de dossiers immuable. Cette arborescence garantit la ségrégation absolue entre la donnée brute, la donnée en cours de traitement, et la donnée scellée (archives). Le programme orchestre silencieusement la lecture, la génération et le déplacement des fichiers au sein de cet environnement.



1.2. L'écosystème de Sécurité (Les Garde-Fous Système)

Au-delà du simple nettoyage de la donnée, le script enveloppe son exécution de sécurités vitales agissant au niveau du système d'exploitation :

- **L'Airbag d'Urgence (Exception Hook) :** En cas de crash Python imprévu (ex : corruption mémoire, donnée non anticipée), une fonction globale intercepte l'erreur fatale avant la fermeture brutale du programme. Elle génère un rapport horodaté dans `data/problemes` et affiche une fenêtre d'alerte explicative pour l'utilisateur, empêchant la perte d'informations sur l'origine de la panne.
- **Le Vigile (OS Permission Check) :** Avant toute phase de création ou de modification d'Excel, le script teste les accès d'écriture en mode *append*. Si un administrateur a laissé un fichier de travail ouvert en arrière-plan, le script intercepte l'erreur `PermissionError`, suspend son exécution et exige la fermeture du document cible pour éviter la corruption de la base de données.

2. Orchestration des Flux : Les Deux Modules ETL

L'application propose deux cycles de traitement distincts, activables depuis le menu principal, correspondant au calendrier institutionnel de l'École Doctorale.

2.1. Module 1 : Statistiques et Effectifs (Campagne de Printemps)

L'architecture de ce module repose sur un pipeline ETL complet, articulé autour de tests bloquants et indicatifs pour garantir l'intégrité des données.

Phase 1 : Ingestion et Tests d'Intégrité Structurelle (Extract)

Le programme charge en mémoire les 9 extractions brutes d'ADUM et déroule immédiatement un protocole de sécurité :

1. **Vérifications d'environnement (Bloquantes) :** Le script exécute un test *Anti-écrasement* en vérifiant si un fichier définitif existe déjà pour l'année saisie. Parallèlement, le test *Anti-oubli* scanne la présence de résidus d'anciennes bases de données et bloque le script si celles-ci ne sont pas sauvegardées dans la mémoire.
2. **Diagnostic Qualité des Fichiers (Le Douanier) :** Le programme applique un dictionnaire de synonymes pour renommer les en-têtes instables d'ADUM (ex : uniformisation de « N° ADUM » en `Matricule`), puis exécute trois tests :
   - **Test de présence :** Vérifie que chaque base de données contient bien toutes les variables attendues.
   - **Test de complétude (Anti-NA) :** Inspecte les colonnes identifiantes critiques (`Matricule`, `Nom`, `Spécialité`). Une seule valeur manquante (*NaN*) entraîne l'arrêt du script avec génération d'un rapport d'erreur.
   - **Test de volumétrie :** Croise les dimensions des matrices complémentaires (Inscriptions vs Financements). Si le nombre d'observations diverge d'une seule ligne, le traitement s'arrête net.

Phase 2 : Moteurs Métiers et Dualité d'Exécution (Transform)

Le script applique sa fonction de nettoyage linguistique (`lisser_texte`) pour supprimer les accents, uniformiser la casse et retirer les espaces inutiles. Il propose ensuite deux modes d'exécution :

Mode 1 : Moteur de Génération du Brouillon de Contrôle

- **Base 1 (Inscrits Actifs) :** Un moteur Regex balaie les textes libres pour traduire les budgets en catégories standardisées (N1 à N4). C'est ici qu'intervient le *Redressement Public/Privé* (un contrat de droit public hébergé par un organisme privé est automatiquement redressé en catégorie publique N3).
- **Base 2 (Suivi des Départs) :** Le script applique une soustraction d'ensembles mathématiques entre l'année $N-1$ et l'année N ($\text{Matricules}_{N-1} \setminus \text{Matricules}_N$) pour capturer les « Fantômes ». Si un abandon survient en $6^{\text{ème}}$ année ou plus, un algorithme scanne le champ commentaire : la présence d'un lemme court lié au mot *"refus"* reclassifie automatiquement le profil en « Délai maximum atteint ».
- **Bases 3 & 4 :** Calcul automatique des durées de recherche et cartographie des effectifs.

L'innovation de l'exportation : Le script n'écrit pas une base figée. Il duplique silencieusement les variables nettoyées dans des **colonnes fantômes masquées** et injecte des menus déroulants. Un audit croisé s'exécute : toutes les contradictions (ex : déclaration SIREDO vs Contrat réel) lèvent un drapeau visuel, colorant les cellules en **Jaune (A vérifier)** ou en **Rouge (Erreur humaine)**. Le script s'arrête et laisse la main à l'humain.

Mode 2 : Moteur de Validation et Certification

- **Test de certification (Bloquant) :** Le script rouvre le fichier corrigé par l'équipe administrative et compare la saisie humaine avec sa colonne fantôme masquée. Si une seule cellule « A vérifier » subsiste, **le script bloque définitivement l'accès à la Phase 3** et renvoie l'utilisateur à sa saisie Excel.

Phase 3 : Centralisation et Historisation Scellée (Load)

Ce bloc final ne s'exécute **que si et seulement si** le Mode 2 a certifié la pureté absolue des fichiers (Zéro anomalie). Le traitement redevient 100% automatisé :

- **Génération des KPIs :** Le script compile les données certifiées pour calculer mathématiquement les 14 indicateurs de performance de l'École Doctorale (taux de financement par labo, attractivité internationale, fuite précoce, etc.).
- **Historisation et Restitution :** Le script ouvre le fichier maître `Historique_Global.xlsx`, y injecte les nouvelles lignes de l'année pour actualiser instantanément les graphiques sur Power BI, puis duplique les fichiers de travail dans un dossier scellé et verrouillé en écriture pour archiver proprement la cohorte.

2.2. Module 2 : Insertion Professionnelle & Alumni (Campagne d'Été)

Le suivi longitudinal des diplômés (Horizons T+1, T+3, T+5) exige une architecture ETL asynchrone. Contrairement aux statistiques, ce module intègre des flux de données externes (LimeSurvey, OSINT sur LinkedIn) et un algorithme complexe de gestion du temps et des contacts.

Phase 1 : Rétro-Ingénierie Temporelle et Matrices de Saisie (Mode 3)

Ce mode prépare le terrain pour l'enquête annuelle en générant les fichiers de travail :

1. **Aiguillage Temporel Dynamique :** L'utilisateur saisit l'année de l'enquête (ex : N). Le script calcule automatiquement les cohortes cibles en rétro-pédalage : $N-1$ (T+1), $N-3$ (T+3), et $N-5$ (T+5). Il ouvre ensuite les dossiers ADUM correspondants.
2. **Fusion Multi-Sources et Master Alumni :** L'algorithme consolide l'identité des docteurs en croisant 4 bases ADUM distinctes (Soutenances, Situation Pro, Réseaux Sociaux, Contacts Encadrants) avec le *Master Alumni* existant, via une clé de jointure robuste (`Nom_Prenom` lissée).
3. **Verrouillage de l'Historique (Anti-Altération) :** Lors de la génération des Excel de saisie, le script repère les colonnes appartenant au passé (ex : la situation T+1 alors qu'on enquête sur T+3). Il applique un formatage grisé et injecte une règle de validation de données stricte (`length < 0`) rendant la modification des anciennes données techniquement impossible sur Excel.

Phase 2 : Algorithme de création de fichier pour LimeSurvey

Parallèlement aux fichiers Excel, le script génère des fichiers CSV standardisées pour l'outil de sondage. Il intègre un **Filtre Intelligent de Messagerie** pour maximiser le taux de réponse :

- Le script analyse via *Regex* le domaine des adresses e-mails (Principal vs Secondaire).
- Si l'e-mail principal est de type universitaire (`unice`, `cotedazur`) – voué à expirer – et qu'un e-mail personnel valide (Gmail, Yahoo, etc.) est détecté en secondaire, l'algorithme bascule automatiquement l'invitation sur l'e-mail personnel.

Phase 3 : Recherche des docteurs sur linkedin et Relances des anciens Directeurs de thèses (Mode 4)

Pendant la phase de collecte (retours LimeSurvey et recherches manuelles sur LinkedIn par l'équipe), certains profils restent introuvables. Le Mode 4 s'active comme un outil d'investigation :

- **Ciblage Automatique :** Le script scanne les brouillons Excel à la recherche des doctorants étiquetés "Perdu de vue" ou "Situation inconnue".
- **Extraction et Génération :** Pour chaque cas identifié, il croise le Matricule avec le Master pour extraire les noms et adresses e-mails des anciens directeurs de thèse et co-encadrants, générant des tableaux de relance ultra-ciblés.

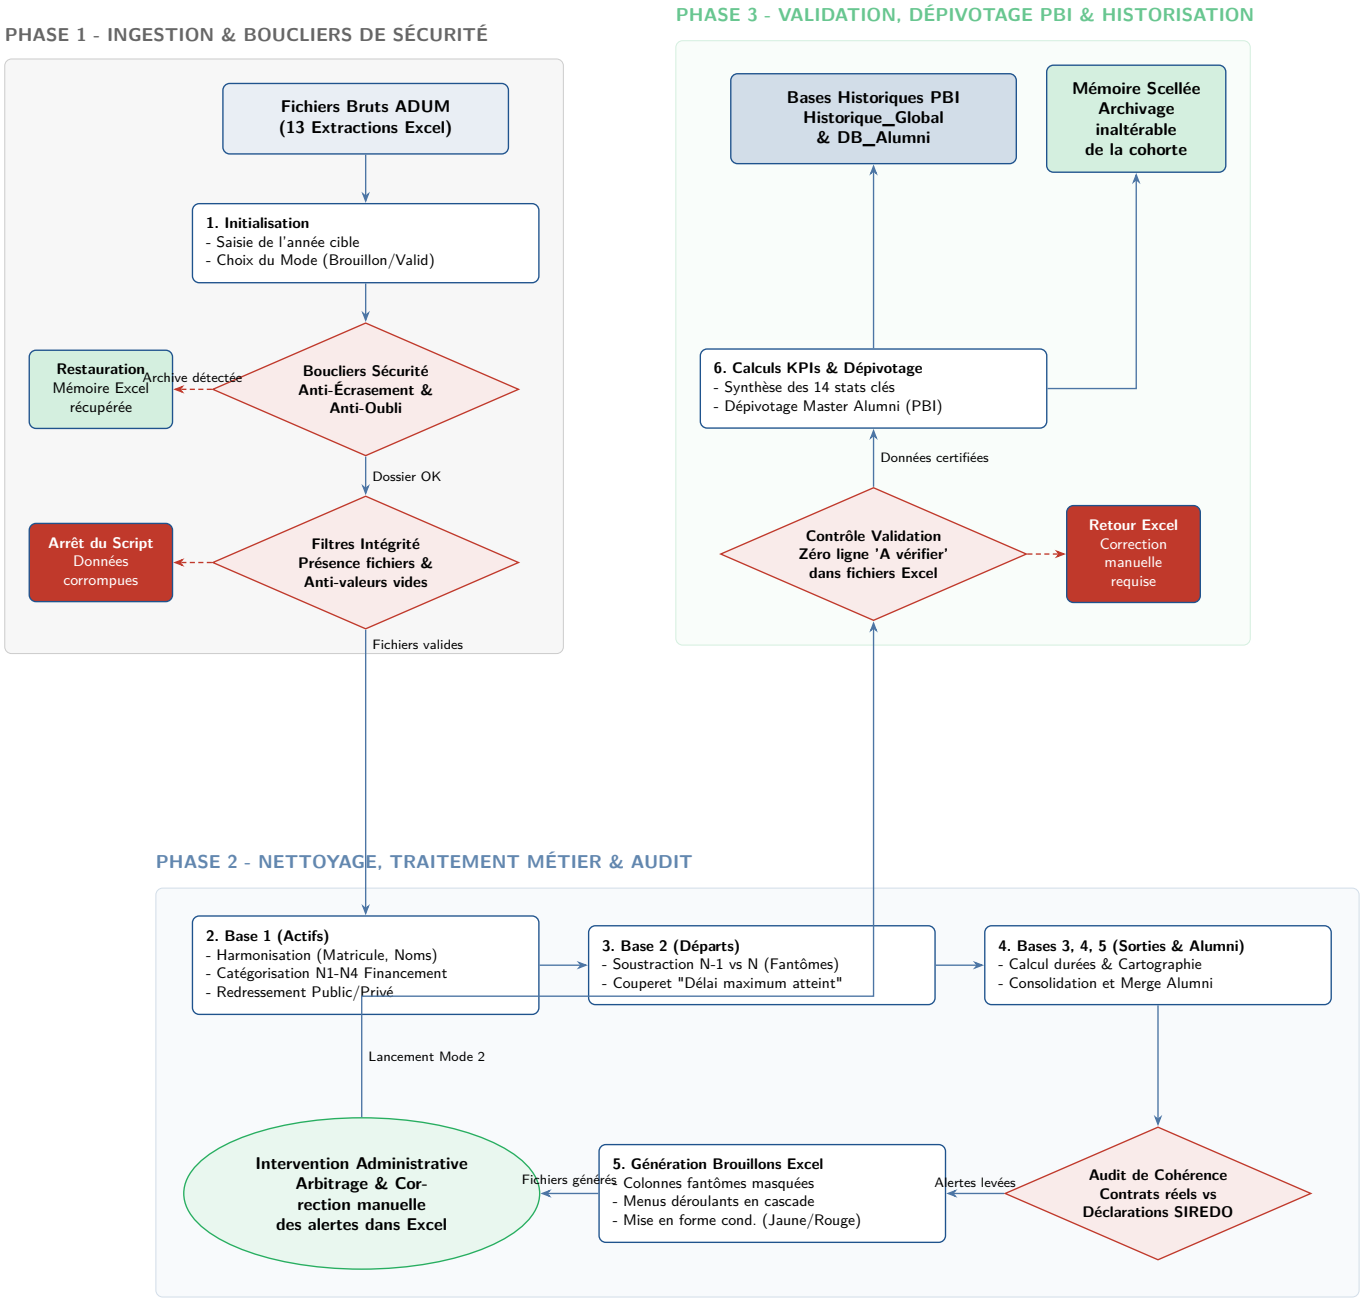
Phase 4 : Dépivotage Massif, Validation et Historisation (Mode 5)

Étape finale bloquante, scellant la fin de la campagne d'enquête.

- **Le Garde-Fou Intégral :** Le script s'assure de l'absence totale de mentions "A vérifier" dans les trois fichiers de saisie simultanément. En cas de succès, les données humaines viennent mettre à jour le *Master Alumni* de manière asynchrone (seuls les champs complétés écrasent les anciens vides).
- **Dépivotage Dimensionnel (Unpivot) :** Les données temporelles (T+1, T+3, T+5) sont en colonnes dans les fichiers de saisie. Le script effectue une transformation matricielle pour les transformer en lignes dans une base relationnelle unique (`DB_Alumni_PBI.xlsx`). Une nouvelle dimension `Horizon` est créée, permettant à Power BI de filtrer dynamiquement l'évolution des carrières.
- **Nettoyage d'Espace :** Le script détruit automatiquement les fichiers de travail et les listes de relances temporaires de la racine, archivant les saisies certifiées dans le dossier `Mémoire` de chaque promotion.

3. Diagramme de Processus Logiciel

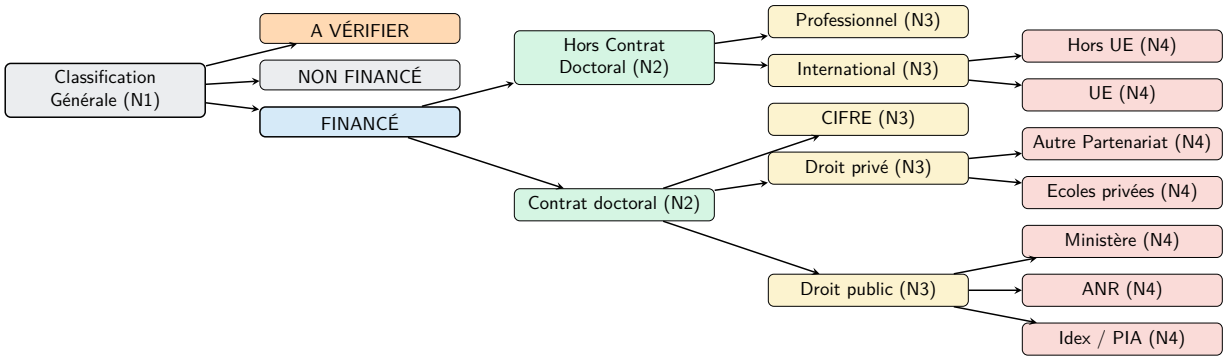
Le logigramme ci-dessous représente le cycle de vie complet de la donnée. Suivant l'architecture, la page est scindée en deux étages bien aérés : les phases d'Ingestion (1) et d'Historisation (3) occupent le haut de l'espace, tandis que la phase de Transformation et d'Audit (2) se déploie largement sur toute la partie inférieure.


PHASE 1 - INGESTION & BOUCLIERS DE SÉCURITÉ
Fichiers Bruts ADUM
(13 Extractions Excel)
1. Initialisation
- Saisie de l'année cible
- Choix du Mode (Brouillon/Valid)
Boucliers Sécurité
Anti-Écrasement &
Anti-Oubli
Archive détectée
Restauration
Mémoire Excel
récupérée
Dossier OK
Filtres Intégrité
Présence fichiers &
Anti-valeurs vides
Arrêt du Script
Données
corrompues
Fichiers valides
PHASE 3 - VALIDATION, DÉPIVOTAGE PBI & HISTORISATION
Bases Historiques PBI
Historique_Global
& DB_Alumni
Mémoire Scellée
Archivage
inaltérable
de la cohorte
6. Calculs KPIs & Dépivotage
- Synthèse des 14 stats clés
- Dépivotage Master Alumni (PBI)
Données certifiées
Contrôle Validation
Zéro ligne 'A vérifier'
dans fichiers Excel
Retour Excel
Correction
manuelle
requise
PHASE 2 - NETTOYAGE, TRAITEMENT MÉTIER & AUDIT
2. Base 1 (Actifs)
- Harmonisation (Matricule, Noms)
- Catégorisation N1-N4 Financement
- Redressement Public/Privé
3. Base 2 (Départs)
- Soustraction N-1 vs N (Fantômes)
- Couperet "Délai maximum atteint"
4. Bases 3, 4, 5 (Sorties & Alumni)
- Calcul durées & Cartographie
- Consolidation et Merge Alumni
Lancement Mode 2
Intervention Administrative
Arbitrage & Cor-
rection manuelle
des alertes dans Excel
Fichiers générés
5. Génération Brouillons Excel
Colonnes fantômes masquées
- Menus déroulants en cascade
- Mise en forme cond. (Jaune/Rouge)
Alertes levées
Audit de Cohérence
Contrats réels vs
Déclarations SIREDO

4. Dictionnaire des Données

4.1. BASE 1 : Les Actifs (Nouveaux Entrants)

Cette base regroupe les étudiants en cours de thèse lors de l'année universitaire analysée. L'indicateur principal est l'algorithme de classification des financements (N1 à N4), généré par le script à partir des colonnes brutes `Financement principal` et `Situation financière 1`.



Focus sur des catégories de financement spécifiques

Professionnel : Désigne les doctorants exerçant une activité professionnelle régulière (CDI, CDD, fonction publique) présentant un lien direct ou une pertinence académique avec leur sujet de recherche. Cette catégorie distingue les doctorants insérés professionnellement de ceux disposant d'un contrat doctoral standard.

Non financé : Regroupe les doctorants ne bénéficiant d'aucun financement dédié à l'élaboration de leur thèse (inclut les doctorants sans emploi et ceux exerçant un emploi purement alimentaire).

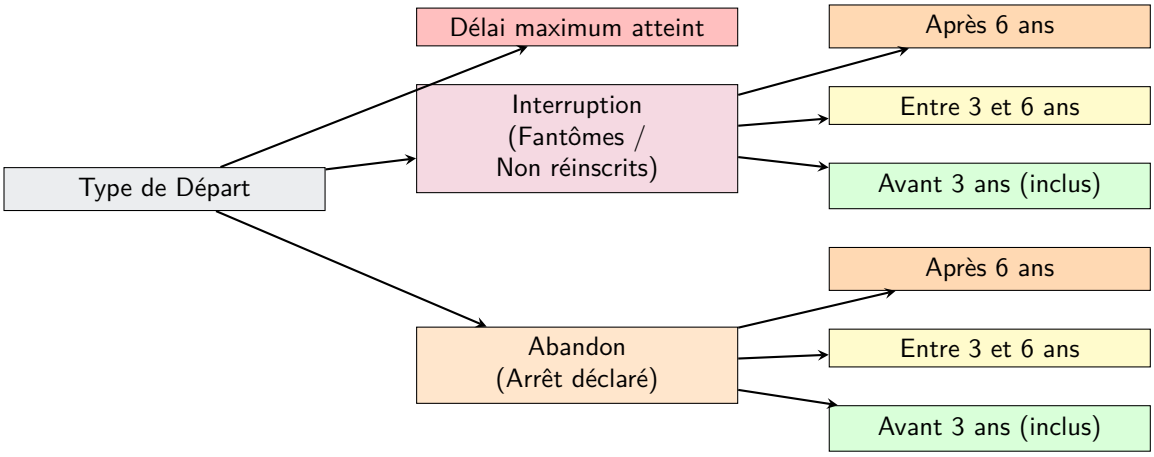
Attributs et Variables de Tri (Base 1 & Base 4)

Ces variables sont nettoyées, normalisées et passées au filtre anti-valeurs vides par le script pour permettre des analyses croisées fiables :

- **Année d'Analyse :** Année universitaire de référence extraite et verrouillée par l'interface lors du lancement du script.
- **Unité de Recherche (Laboratoire) :** Centre de recherche de rattachement du doctorant, harmonisé par le script pour regrouper les effectifs par entité scientifique.
- **Typologie Établissement (Master) :** Établissement d'obtention du diplôme de Master : Université Côte d'Azur / Autre Université Française / Ecole de Commerce ou Ingénieur / Université Étrangère (UE) / Université Étrangère (Hors UE).
- **Typologie Nationalité :** Origine géographique de l'étudiant classée en trois zones : Française / UE / Hors UE.
- **Discipline :** Grand domaine scientifique de la thèse : Économie / Gestion / Droit & Science Politique.

4.2. BASE 2 : Les Départs (Abandons & Interruptions)

Base isolant les étudiants n'étant plus inscrits d'une année sur l'autre. Elle catégorise le motif de départ, l'ancienneté au moment de la sortie, et conserve les axes d'analyse clés transférés par le script pour étudier la structure des départs.



Règle de redressement (Le couperet temporel)

L'algorithme reclasse automatiquement en **"Délai maximum atteint"** :

- Toute disparition inexpliquée (Interruption / Fantôme) survenant en 6ème année ou au-delà.
- Tout arrêt déclaré (Abandon) en 6ème année ou au-delà dont le commentaire d'arrêt contains le mot-clé *"refus"*.

Variables conservées pour l'analyse des départs

Pour permettre l'identification des facteurs de risques d'abandon dans Power BI, le script associe systématiquement à chaque départ :

— **Discipline :** Permet de détecter les taux de rupture par grand domaine (Économie / Gestion / Droit).

— **Unité de Recherche (Laboratoire) :** Utile pour repérer d'éventuelles anomalies ou fragilités localisées par équipe d'accueil.

4.3. BASE 3 : Les Soutenances

Base regroupant exclusivement les étudiants ayant validé et soutenu leur thèse au cours de l'année analysée.

— **Catégorie Durée (hors césure) :** Temps exact écoulé pour la recherche : Moins de 3 ans / Entre 3 et 4 ans / Entre 4 et 5 ans / Entre 5 et 6 ans / Plus de 6 ans.

— **Cotutelle Internationale :** Zone géographique du partenariat étranger : UE / Hors UE / *Vide*.

— **Césure :** Indicateur (Oui / Non /A vérifier) signalant si le doctorant a temporairement suspendu ses recherches de manière officielle.

— **Discipline :** Permet de détecter les taux de rupture par grand domaine (Économie / Gestion / Droit).

— **Unité de Recherche (Laboratoire) :** Utile pour repérer d'éventuelles anomalies ou fragilités localisées par équipe d'accueil.

4.4. BASE 4 : Le Registre des Effectifs Globaux

Cette table constitue la base de référence pour le calcul de l'ensemble des volumes annuels de l'école doctorale. Contrairement aux bases ciblées (nouveaux entrants ou départs), elle offre une vision "photographique" complète à un instant T.

Variables majeures consolidées

— **Stock Total des Inscrits :** Nombre absolu de doctorants actifs, toutes années de thèse confondues (de la 1A à la 6A+).

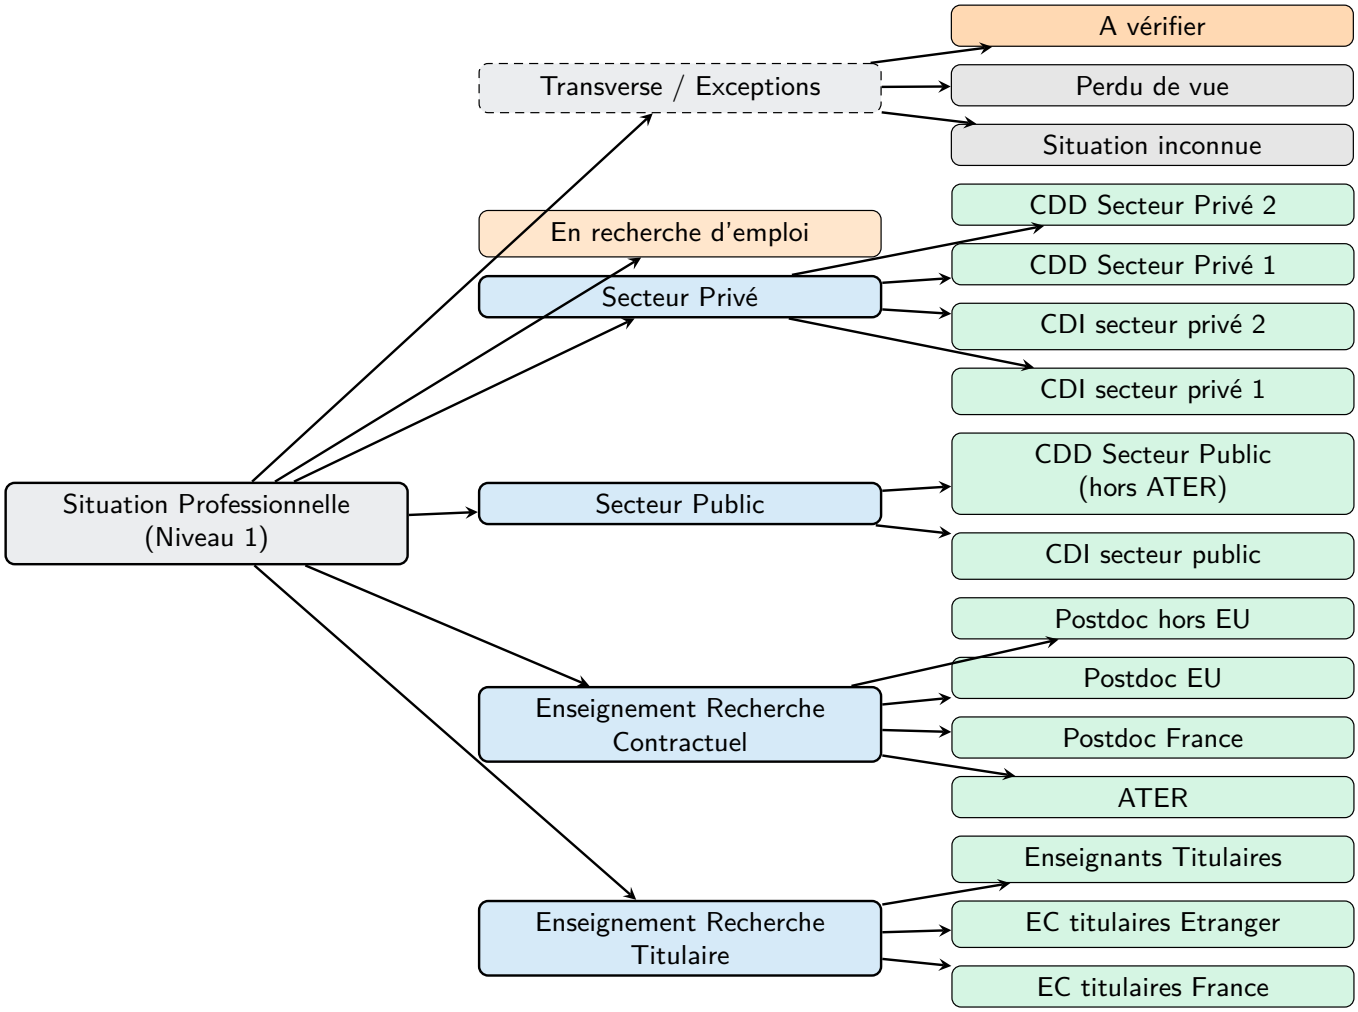
— **Discipline :** Permet de détecter les taux de rupture par grand domaine (Économie / Gestion / Droit).

— **Unité de Recherche (Laboratoire) :** Utile pour repérer d'éventuelles anomalies ou fragilités localisées par équipe d'accueil.

4.5. BASE 5 : Le Suivi Alumni (Insertion Professionnelle)

Cette base assure la traçabilité des parcours professionnels des docteurs après leur soutenance (horizons T+0, T+1, T+3, T+5). Le pipeline intègre un nettoyage des URLs LinkedIn et déploie une arborescence de classification métier permettant de segmenter finement les trajectoires d'insertion.

Architecture de Classification (Niveau 1 & 2)



Dépivotage et Modélisation Power BI

L'innovation majeure de ce module réside dans la préparation de la donnée pour le Dashboard :

— **Consolidation des Horizons Temporels :** Lors du traitement (Mode 2), l'algorithme ne se contente pas d'exporter les différentes bases de suivi (T+0, T+1, T+3, T+5) de manière isolée. Il effectue un *dépivotage* (unpivot) massif du `Master_Alumni`.

— **Génération de la Base Unique :** Les différentes colonnes temporelles sont transformées en lignes pour créer une unique table relationnelle (`DB_Alumni_PBI.xlsx`). Cette table standardisée intègre une nouvelle

dimension `Horizon`, permettant à Power BI de filtrer dynamiquement les situations professionnelles (N1 et N2) selon l'ancienneté de la soutenance, tout en garantissant le suivi longitudinal via l'identifiant unique.